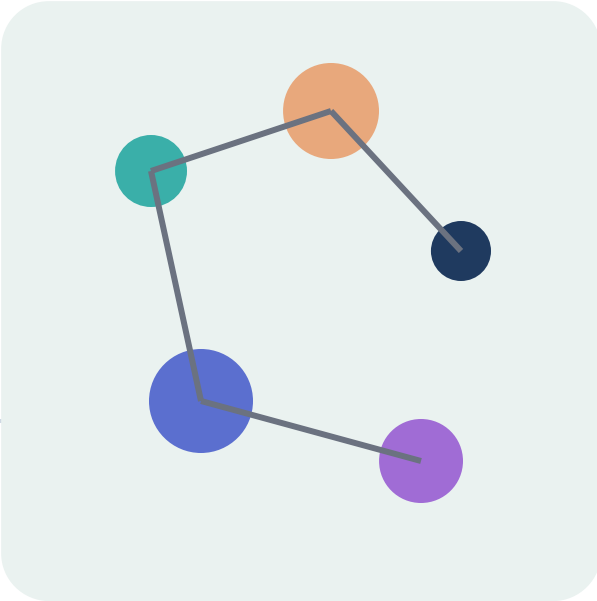
从细胞身份到组织空间

单细胞与空间转录组联合分析

单细胞回答：有哪些细胞、处于什么状态

空间转录组回答：它们在哪里、和谁相邻



名单 → 地图 → 机制

A REAL COUNT TABLE

一张 0 太多的表，先不解释

bulk 测序给的是群体平均，这张表逐个细胞给出真实计数

GENE	细胞 1	细胞 2	细胞 3	细胞 4	细胞 5	细胞 6
CD3D	0	**15**	0	1	0	4
MS4A1	**3**	0	0	1	0	0
LYZ	0	0	0	**98**	0	0
NKG7	0	**14**	**35**	0	0	1
PPBP	0	0	0	1	**54**	0
HLA-DRA	**16**	1	0	6	1	1

sclet 读入的经典小数据 pbmc_small（80 细胞 × 230 基因）——全矩阵 75.8% 的格子是 0

- 36 个格子里 20 个是 0——这份数据是不是坏了？
- LYZ 只在细胞 4 亮（98），PPBP 只在细胞 5 亮（54）
- CD3D 在细胞 2 是 15，别处几乎都是 0——谁在表达它？
- 把 6 列平均成一个「平均细胞」，这张表还剩什么？
- 这份名单还缺少位置与邻域，后面要把它放回组织

先记住这张表——身份要从矩阵中读出，位置要回到组织中找

今天的路线

从一份细胞名单，走到一个机制模型

身份

有哪些细胞？

状态

它们在做什么？

位置

它们在哪里？

邻域

谁和谁相邻？

机制

能否形成机制假说？

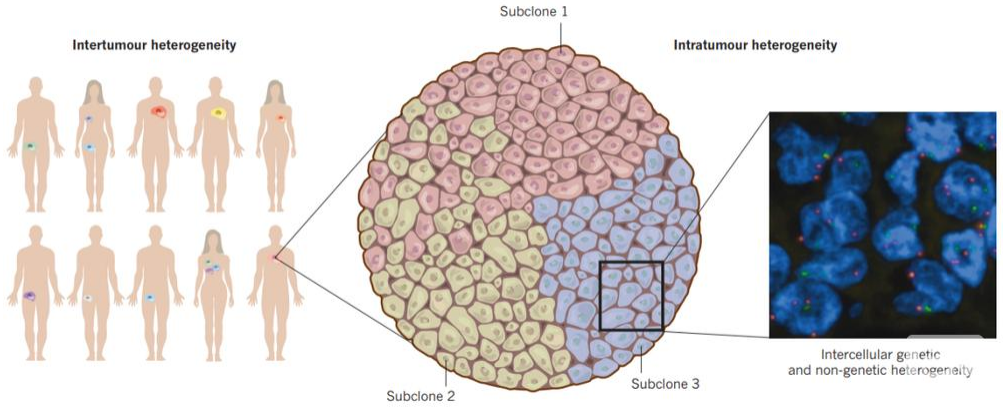
sclet 贯穿前半段：每一步把结果写进状态层，也让下一步知道自己能不能开始。

KEY FACT

细胞具有异质性

同一块组织里的细胞，可能完全不是一类东西

- 看起来一样的细胞，表达谱可能天差地别
- 异质性来自发育阶段、细胞状态、微环境
- 肿瘤内部的异质性直接关系治疗响应
- 免疫细胞的亚群决定了免疫应答的走向
- 忽略异质性，就可能得出错误结论



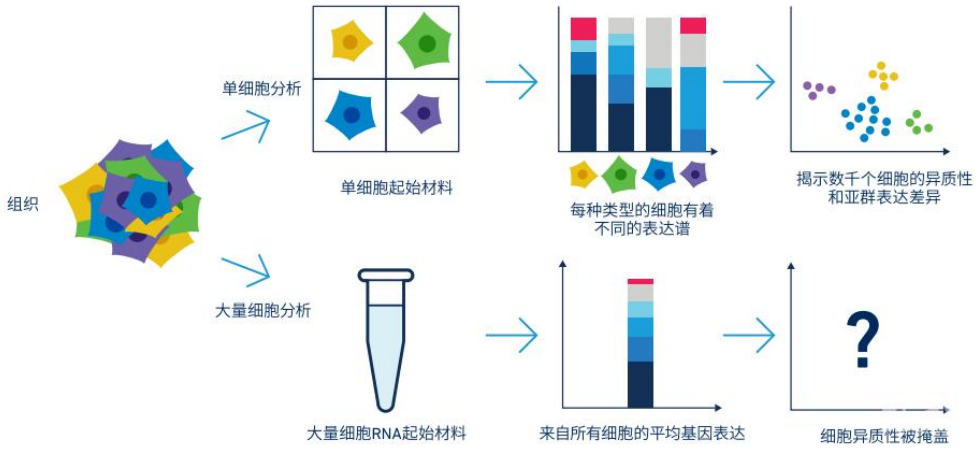
组织内部的细胞异质性

THE PROBLEM

细胞特异性在传统转录组里被掩盖

把一万人混在一起测序得到的是「平均人」——一个基因升高，也可能只是表达它的细胞变多了

- bulk RNA-seq 混合了成千上万个细胞
- 稀有细胞群体的信号会被完全淹没
- 结论：bulk 告诉你「组织里有什么」，单细胞告诉你「每个细胞在做什么」
- 一个亚群的高表达可能被另一个亚群的低表达抵消
- 平均之后，细胞状态之间的相关性也消失了

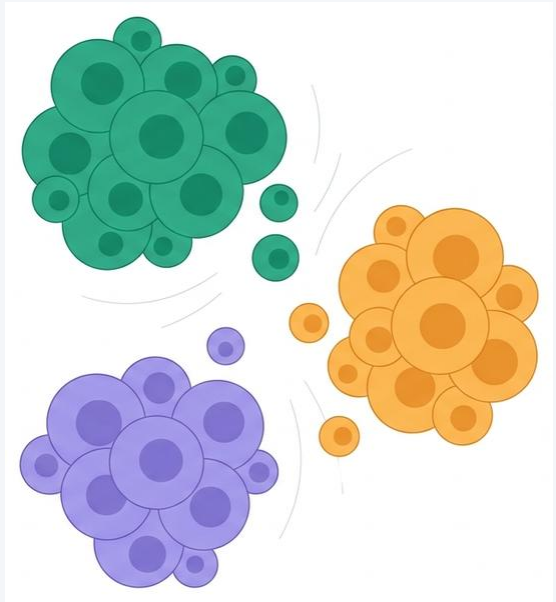


bulk 测序对细胞特异性的平均效应

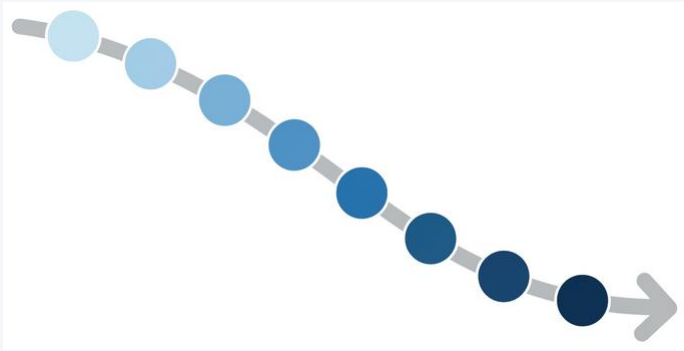
WHY SINGLE CELL

单细胞能回答 bulk 回答不了的问题

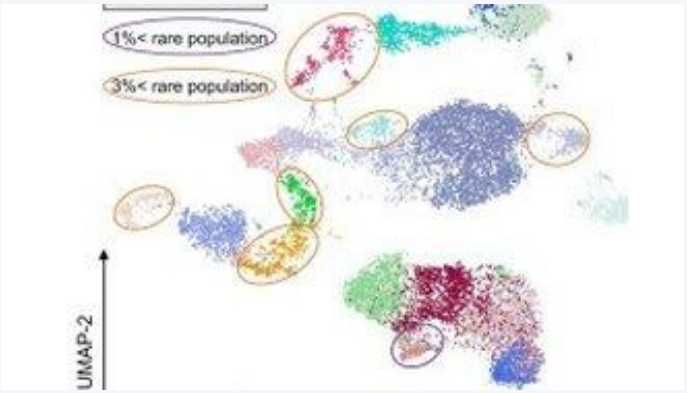
核心在于把「一个样本」拆成「一群细胞」



识别新的细胞类型



刻画细胞状态连续变化



发现稀有细胞群体（Wang et al. 2024）

COMPARE

bulk 与单细胞的根本差别

不是精度差别，是问题类型差别

bulk RNA-seq

- 一个样本得到一个表达谱
- 反映组织平均水平
- 稀有细胞群体被淹没
- 成本低、深度高、技术成熟
- 适合：组间比较、大样本队列

单细胞 RNA-seq

- 一个样本得到数千到数十万表达谱
- 反映每个细胞的状态
- 能识别稀有亚群与新类型
- 成本高、每细胞深度低、数据稀疏
- 适合：细胞组成、状态转变、异质性

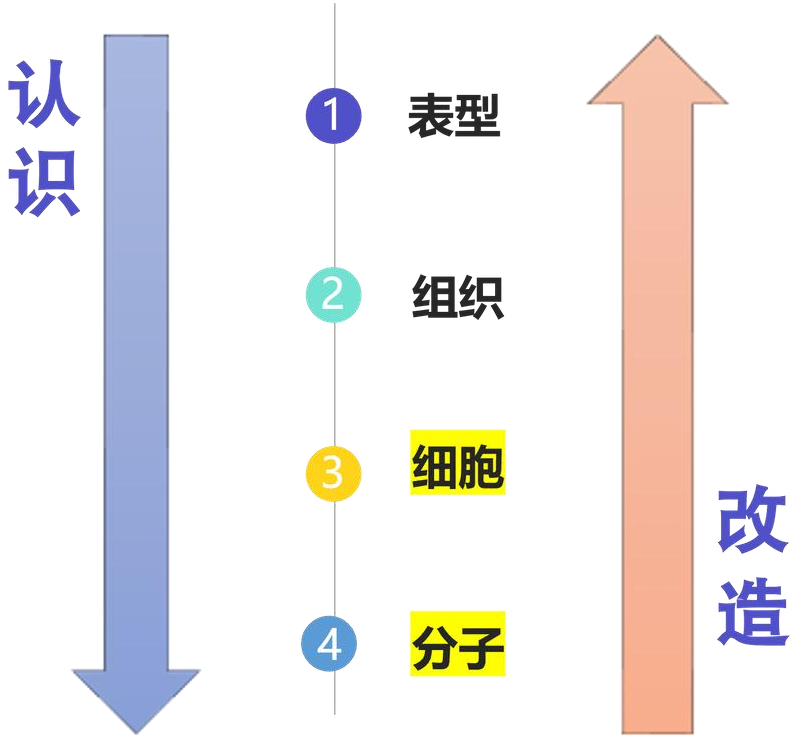
单细胞不是 bulk 的升级版，而是回答另一类问题的工具

THE GAP

单细胞丢掉了什么

位置，正是细胞实际发挥作用的场所

- 单细胞技术是解析细胞异质性的有力工具
- 但它需要把组织解离成单个细胞悬液
- 解离过程彻底破坏了原位空间信息
- 「细胞—分子」关系是系统性理解生物学过程的关键信息
- 缺失位置，就无法回答「谁在和谁相互作用」



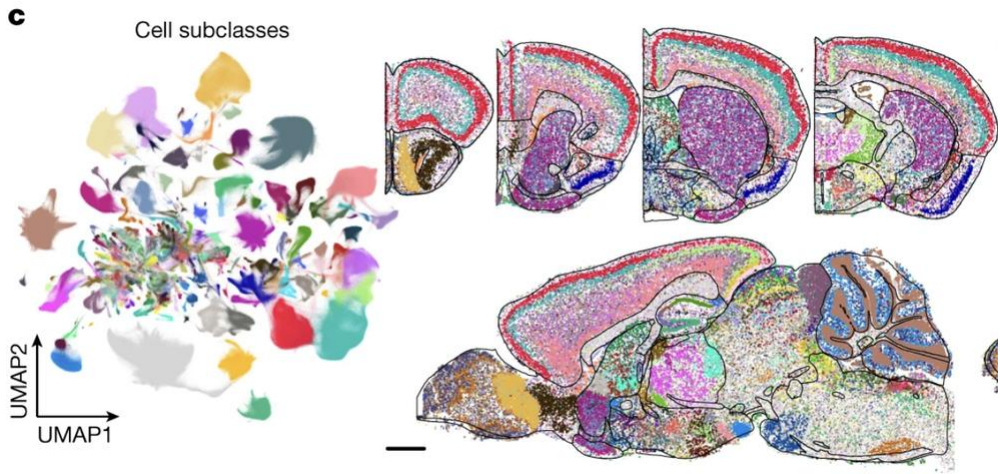
单细胞丢失原位信息的示意

THE ANSWER

空间技术进一步具象化了「细胞异质性」

不只是「有哪些细胞」，而是「它们在哪里」

- 空间转录组补充了单细胞丢失的原位信息
- 在部分场景下可以减少对单细胞转录组的依赖
- 让细胞类型与组织结构直接对应
- 为细胞间通讯分析提供真实的邻接关系
- 这是从「细胞列表」到「组织地图」的跃迁



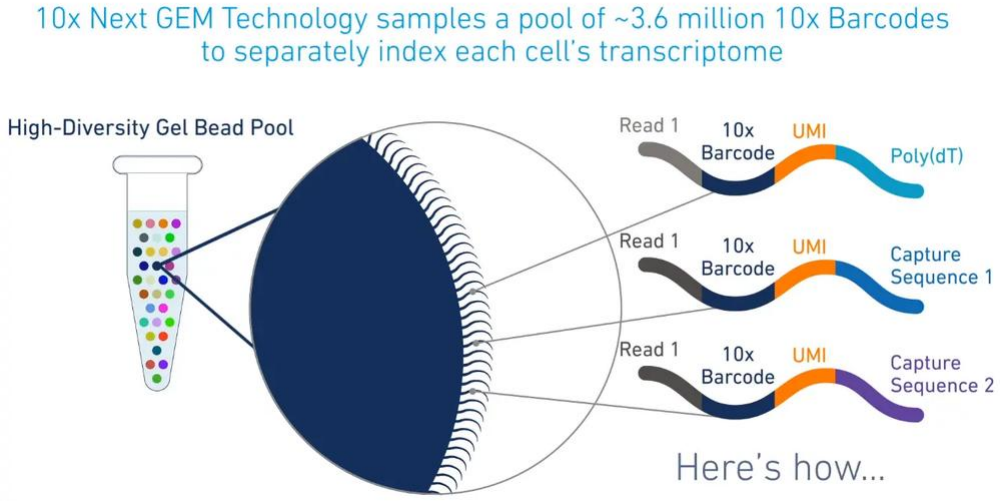
空间信息带来的新维度

THE CORE IDEA

核心问题：需要大量标签区分细胞

没有标签，测完就不知道哪条读段属于哪个细胞

- 每个细胞需要一个唯一的标识（cell barcode）
- 每条 mRNA 需要一个唯一分子标识（UMI）
- barcode 区分细胞，UMI 区分分子
- 两个标签组合，才能从混合测序数据里还原单个细胞
- 这是所有液滴式单细胞平台的基础设计



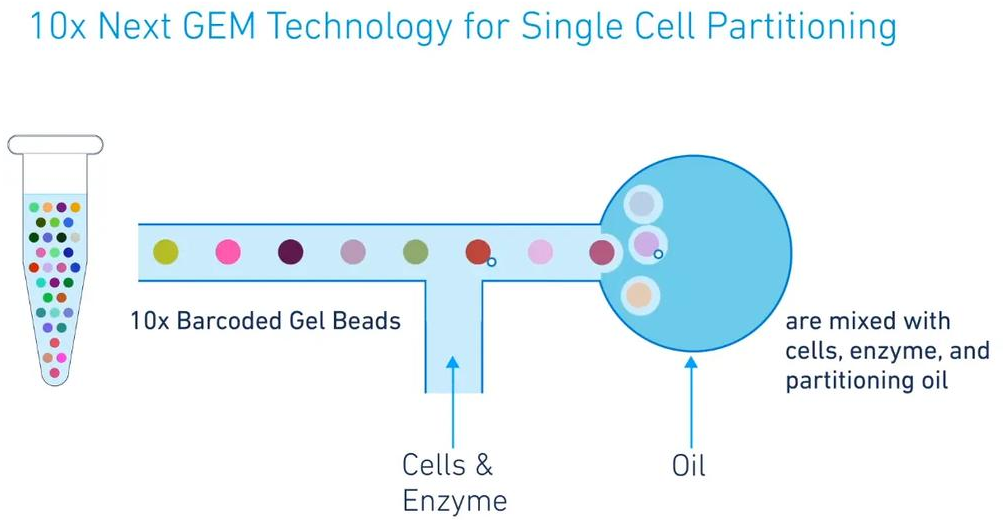
barcode 与 UMI 的作用

HOW IT WORKS

分离细胞并打上标签

一个液滴里只装一个细胞和一颗凝胶珠

- 细胞悬液与凝胶珠（bead）在微流控芯片中相遇
- 每个 bead 表面带有大量相同的 barcode 序列
- 理想情况：一个液滴 = 一个细胞 + 一个 barcode
- 油相把两者包裹成一个个独立液滴
- 细胞裂解后，mRNA 被捕获并加上 barcode 与 UMI



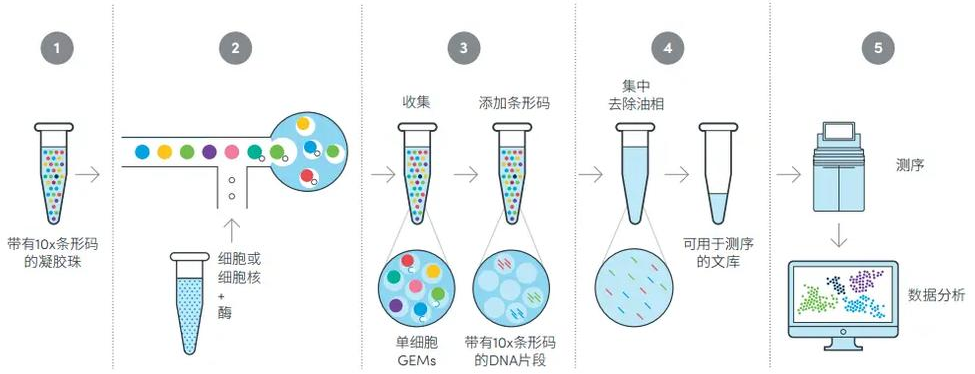
液滴微流控的工作方式

WORKFLOW

单细胞转录组测序的完整流程

从组织到表达矩阵

- 1. 组织解离成单细胞悬液
- 2. 液滴包裹，细胞裂解，mRNA 捕获
- 3. 逆转录为 cDNA，同时写入 barcode 与 UMI
- 4. 建库、测序
- 5. 按 barcode 拆分数据，得到细胞 × 基因的表达矩阵



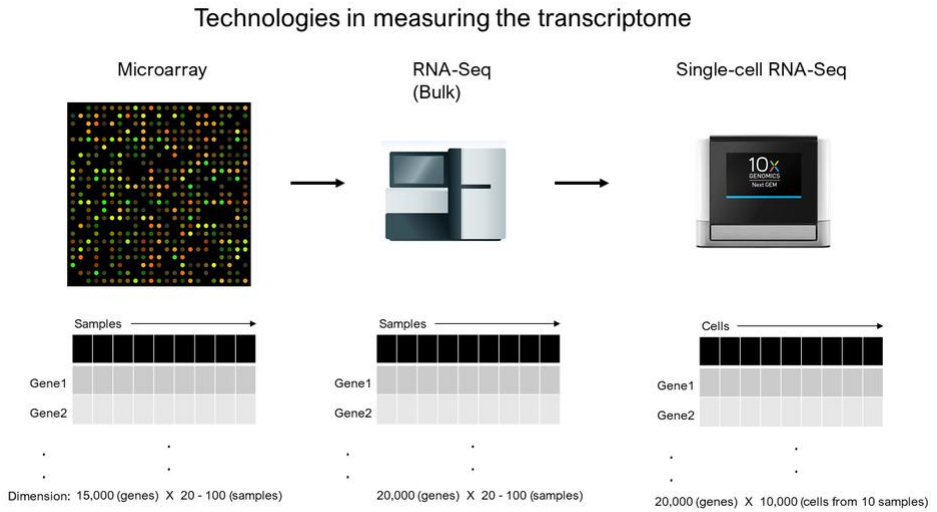
单细胞测序流程

LANDSCAPE

转录组技术的谱系

单细胞是这条线上的一站

- bulk RNA-seq：组织平均水平
- 低通量单细胞（plate-based）：几百个细胞，深度高
- 高通量液滴单细胞：数千到数十万细胞，深度浅
- 单细胞核测序（snRNA-seq）：适合冻存与难解离组织
- 空间转录组：保留位置信息，与单细胞互补



转录组技术家族

DROPOUT

为什么会 dropout

理解这一点，后面很多分析设计就说得通了

捕获效率

只有一部分 mRNA 被成功捕获并逆转录

测序深度

每个细胞分配的读段有限，低表达基因容易漏掉

技术噪声

液滴形成、裂解、建库各环节都有损失

生物学原因

转录是脉冲式的，同一基因在不同时刻拷贝数波动很大

后果

表达量出现大量 0，相关性与距离度量都会失真

应对

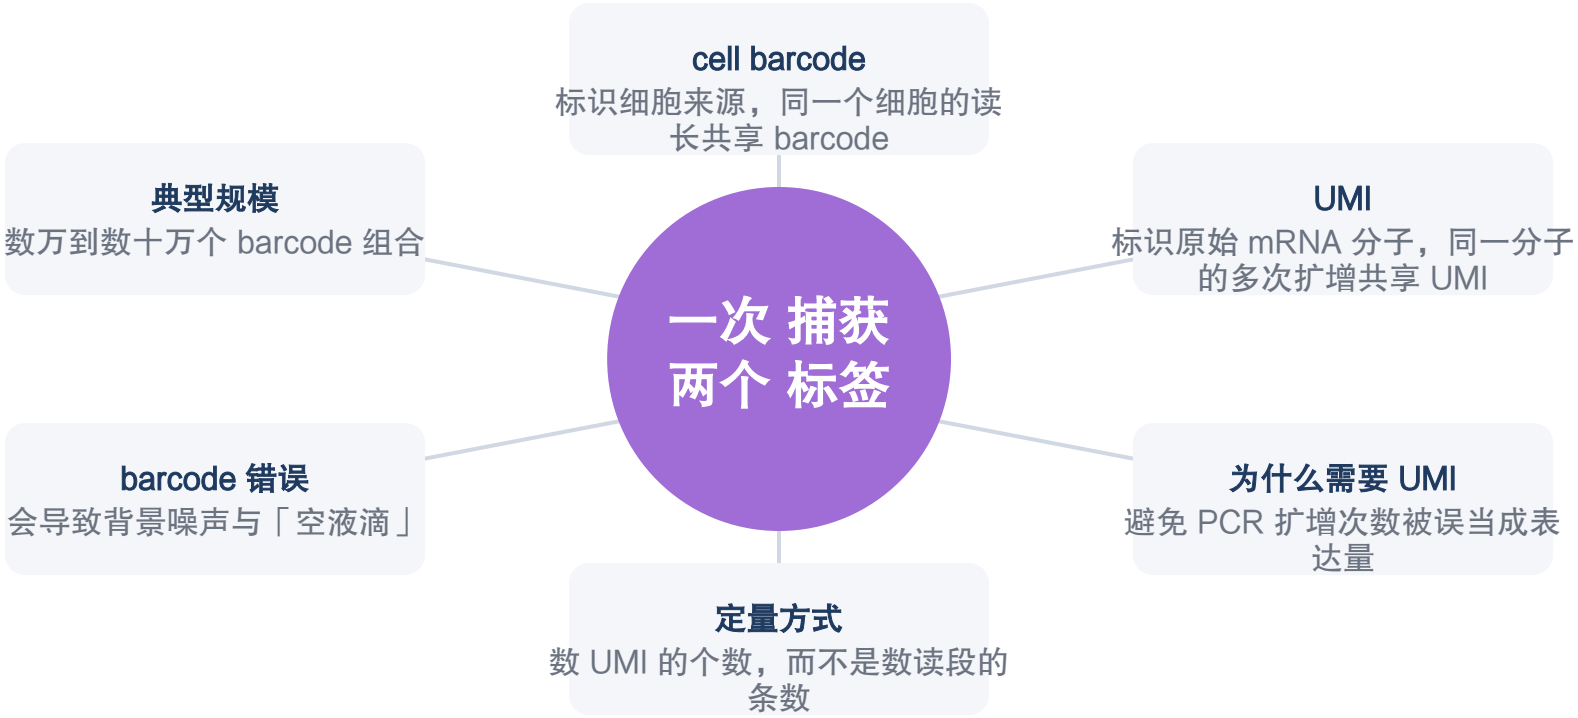
imputation、meta cell、或选择对稀疏性鲁棒的方法

不要试图「修好」所有的 0，先想清楚它来自哪里

TWO LABELS

barcode 与 UMI：两个标签，两个职责

把它们混起来，是最容易犯的概念错误



barcode 回答「哪个细胞」，UMI 回答「几个分子」

PLATFORMS

常见单细胞平台对比

选平台的三个关键词：通量、深度、是否全长

平台类型	通量	每细胞深度	读段位置	典型用途
Plate-based	低（百级）	高	全长	深度刻画少量细胞
液滴 3' 端	高（万—十万级）	低—中	3' 端	常规细胞图谱
液滴 5' 端	高	低—中	5' 端	免疫受体序列、VDJ 分析
单细胞核	高	低—中	3' / 5'	冻存样本、难解离组织
全长单细胞	中	高	全长	可变剪接、融合基因、突变

先问「要不要看剪接和突变」，再决定是否需要全长方案

MULTI-OMICS

在同一个细胞里同时测两种分子

转录组加表观组，才有资格谈「调控」而不只是「相关」

		RNA	甲基化	开放染色质	gDNA / CNV
scG&T-seq	基因组与转录组同测	●			●
scM&T-seq	甲基化与转录组同测	●	●		
scNMT-seq	转录、甲基化、染色质三层	●	●	●	
sci-CAR	染色质可及性与转录组同测	●		●	

更高的组合：scTrio-seq 把甲基化、gDNA 与 CNV 放进同一个细胞，scCOOL-seq 再加一层染色质状态

sclet 用 altExp 承载第二套模态：RunMultimodalWorkflow() 统一调度，register_multimodal_adt() / _atac() 负责登记

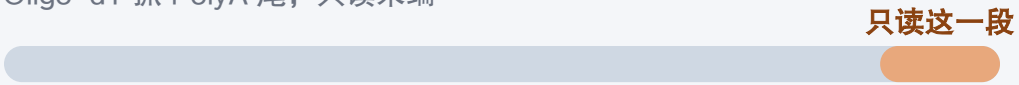
FULL-LENGTH COVERAGE

全长方案看得到 3' 方案看不到的地方

用模板切换或随机引物，覆盖从一端扩展到整条转录本

3' 端方案

Oligo-dT 抓 PolyA 尾，只读末端



通量高，单细胞成本低

覆盖长度约为转录本的十分之一

看不到剪接、融合与突变

非 polyA 的 RNA 直接漏掉

全长方案

Smart-seq2/3 · MAS-seq · scFAST-seq



通量通常更低，成本更高

5' 到 3' 端覆盖更均匀

可变剪接、融合基因、突变可查

非 polyA 转录本也能被抓到

选择只看一个问题：我的问题需要看到转录本的哪一段?

只关心表达量——3' 端方案足够，通量还更高

要看可变剪接、新异构体、融合变异或靶向突变——必须换全长方案

混样建库（MAS-seq）是全长方案提高通量的常用办法

PART 03

把数据洗干净

03

矩阵到手后的第一件事：QC、双联体、归一化

- 数据对象与读入：sclet（SCE 容器）/ Seurat / AnnData
- QC：阈值是薛定谔的细胞
- 环境 RNA 与双联体：两种假信号
- 归一化与高变异基因：让会说话的基因先开口

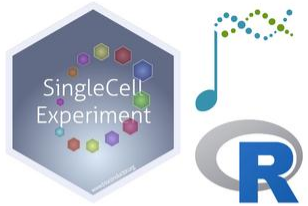
TOOLS

分析工具的地形图

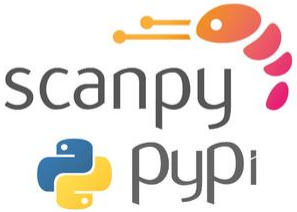
sclet 不是容器选型，是状态契约

- **sclet：我们的主线**
  对象自己记住做过什么
  • Status() 一键查看
  • github.com/YuLab-SMU/sclet
- **SingleCellExperiment**
  Bioconductor 的通用容器
  统计方法丰富
- **Seurat**
  功能完整、上手快
  文档丰富
- **Scanpy**
  Python 生态的实现
  与 AnnData 配套

- **别的工具靠你记住参数，sclet 靠 Status() 替你记住**







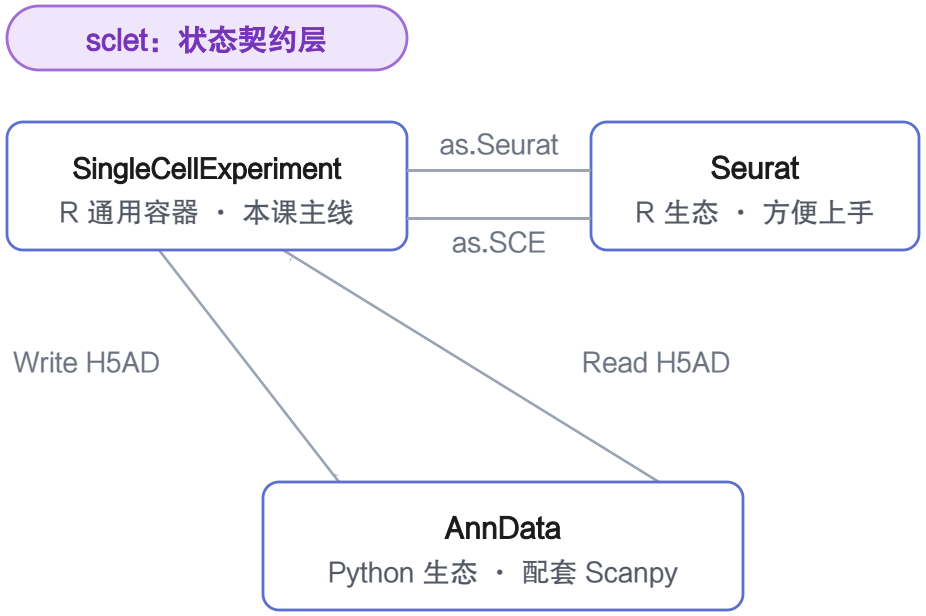
单细胞分析工具生态

CONTAINERS

Seurat 是城堡，SingleCellExperiment 是大陆

城堡好用，大陆更自由

- Seurat：功能完整、文档丰富
  上手快，生态围绕它展开
- SingleCellExperiment：
  Bioconductor 通用容器，
  可与大量统计方法组合
- AnnData：Python 侧的
  结构，与 Scanpy 配套
- 三者之间可以相互转换
- 本课用 sclet：SCE 内核
  + 状态契约，每一步都能追溯



不同数据结构的关系（sclet：github.com/YuLab-SMU/sclet）

DATA STRUCTURES

SingleCellExperiment：一个容器，四个部件

理解容器结构，才不会被各种对象搞晕



表达矩阵

cell	nCount	pctMT	type
AAAC	3200	8.2	B cell
AAAC	1800	4.5	T cell
AAAC	5200	12.1	Monocyte

细胞元数据

gene	chr	HVG
CD3D	chr11	yes
MS4A1	chr11	yes
NKG7	chr19	no

基因元数据



降维结果

STATE CONTRACT

跑完一键流程，对象自己记得发生了什么

一次调用展开成七步真实函数，Status() 一眼看清当前状态

RunStandardPipeline() 内部依次调用

1. NormalizeData(sce)
2. FindVariableFeatures(sce)
3. ScaleData(sce)
4. RunPCA(sce)
5. FindNeighbors(sce)
6. FindClusters(sce)
7. RunUMAP(sce)

注释、富集属于下一步分析，不在这个入口里

同名但实现不同：七步跑在 scuttle / scater / igraph 上
参数与 Seurat 版不通用——照抄 Seurat 教程的参数会报错

Status(pbmc) 的输出

```
# 跑 RunStandardPipeline() 之前
active$reduction: NULL
available$analyses: NULL
n_commands: 0

# 跑完 RunStandardPipeline() 之后
active$assay: "scaled"
active$reduction: "UMAP"
active$graph: "knn_graph"
available$analyses: "hvg"
n_commands: 7
last_command: "RunUMAP"
```

下游 FindNeighbors() 不用你手动指定用哪个 reduction——active 已经指向刚算完的那个

sclet 接口：RunStandardPipeline() 一键跑通；PipelineSummary(pbmc) 给出结构化文字报告

STEP 1 · LOAD

读取数据：先看一眼再动手

不建议两眼一抹黑就把数据滤了

- 常见输入：10x CellRanger 输出的三个文件
- barcodes.tsv：细胞标签
- features.tsv：基因信息
- matrix.mtx：稀疏表达矩阵
- 读入后先看维度、稀疏度，再看几个真实细胞的计数

sclet 读取并查看数据

```
# 读入 10x 三件套（Read10X 内部已算 QC 指标）
sce <- Read10X("filtered/")
# 看维度：基因数 × 细胞数
dim(sce)
[1] 32738 2700

# 看稀疏度：矩阵里 0 占多少
mean(assay(sce, "counts") == 0)
[1] 0.9741

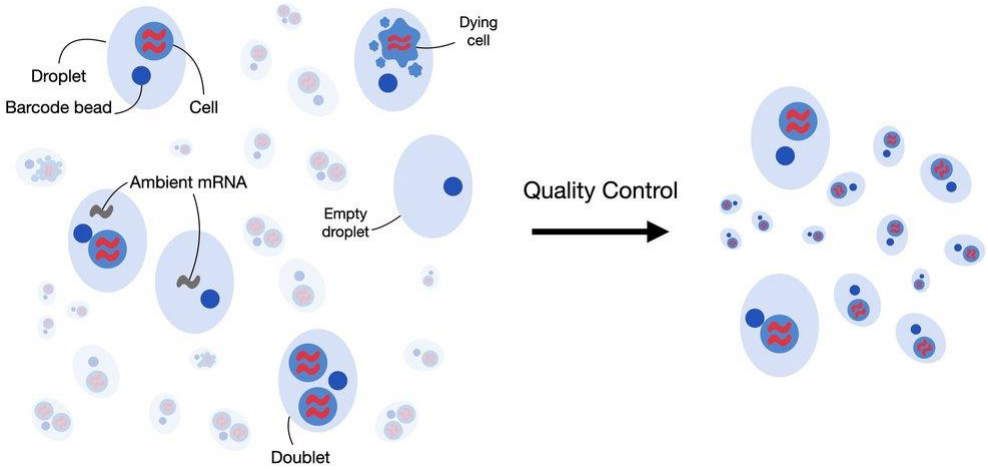
# 挑三个基因、四个细胞，看原始计数
assay(sce, "counts")[c("CD3D","LYZ","NKG7"), 1:4]
      [,1] [,2] [,3] [,4]
CD3D    4    0   10    0
LYZ     1    3    2   24
NKG7    0    1    0    1
```

STEP 2 · QC

QC：过滤低质量数据

这一步做错，后面全白做

- 低质量细胞会带来虚假的差异与聚类
- 双细胞（doublet）会表现出混合的表达特征
- QC 的目标不是「滤得干净」，而是「滤得合理」
- 空液滴（empty droplet）只有极少基因被检测到
- 死细胞会释放线粒体 RNA，导致线粒体比例升高



QC 要过滤掉的三类问题细胞

THREE METRICS

三个核心 QC 指标

每个指标都要问「高」和「低」分别意味着什么

检测到的基因数

空液滴很少；低质量细胞很少；双细胞异常高

检测到的读段总数

反映测序深度与细胞大小，需结合基因数一起看

线粒体基因比例

低质量或死亡细胞通常有线粒体污染，比例偏高

还要看什么

血红蛋白基因比例（血液污染）、核糖体基因比例、top 基因占比

怎么判断

看分布图，找自然断点，而不是照抄一个数字

顺序建议

先粗滤掉明显异常，聚类后再回来精调

三个指标要联合判断，单看任何一个都会误伤

A SHARP LINE

“

看图设阈值，多数人只是照抄代码。—— 薛定谔的阈值

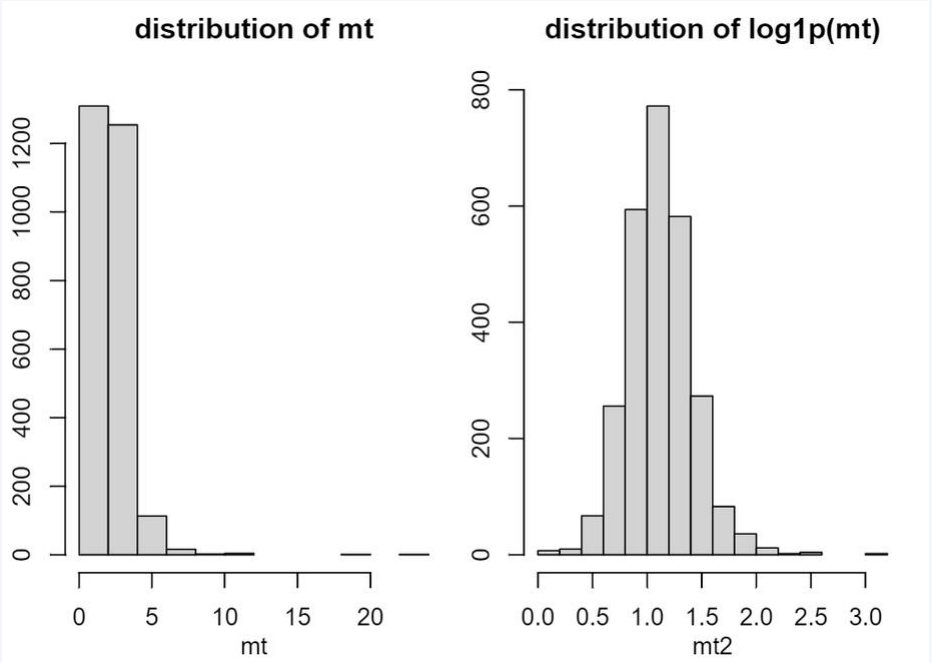
THINK

当你在过滤时，你在干什么?

每一次过滤都是在做一次生物学假设

```
> mt <- pbmc[[]]$percent.mt
> # > 5 滤掉多少比例
> mean(mt > 5)
[1] 0.02111111
> # 用正态分布来过滤（你看过数据分布吗？）
> cutoff <- mean(mt) + 2 * sd(mt)
> cutoff
[1] 4.546009
> mean(mt > cutoff)
[1] 0.03111111
> # log1p才正态（还是要看分布确认一下）
> mt2 <- log1p(x$percent.mt)
> cutoff <- mean(mt2) + 2*sd(mt2)
> mean(mt2 > cutoff)
[1] 0.03074074
> # 超过95%就被滤掉
> quantile(mt, .95)
     95%
4.014658
> # MAD: 偏离中位数的中位数
> cutoff <- median(mt) + mad(mt) * 3
> cutoff
[1] 4.432173
> mean(mt > cutoff)
[1] 0.03444444
>
```

用不同方法过滤线粒体比例

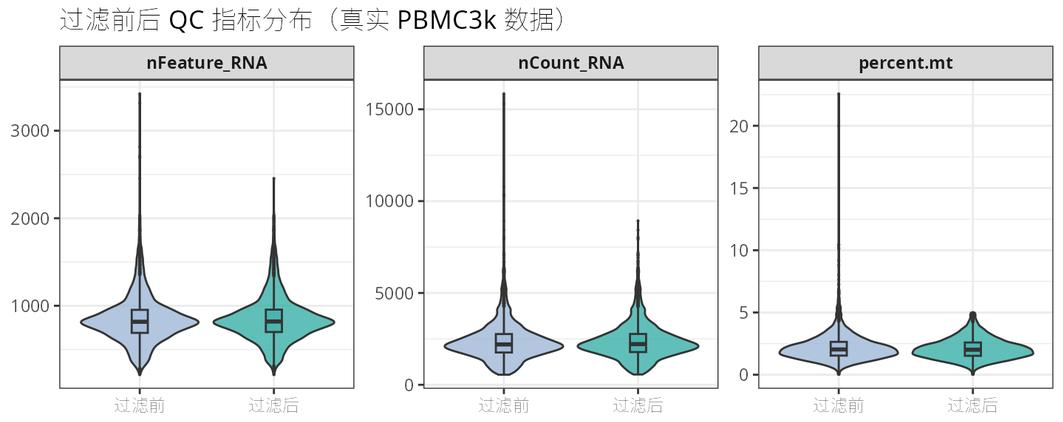


线粒体比例分布（原始 vs log1p）

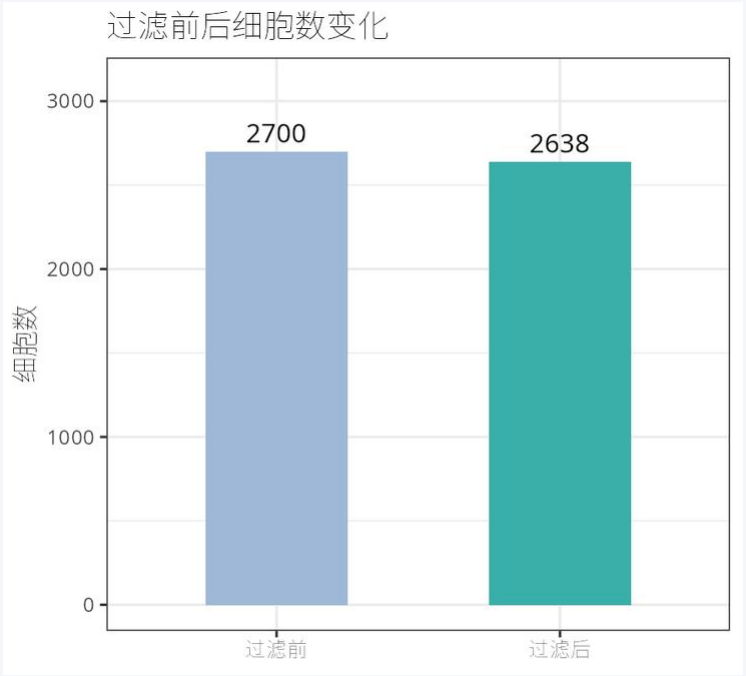
AFTER FILTERING

过滤前后对比

PBMC3k 真实数据：同一批细胞，过滤前后放在一起看



nFeature_RNA、percent.mt 的长尾被切掉，nCount_RNA 几乎不变



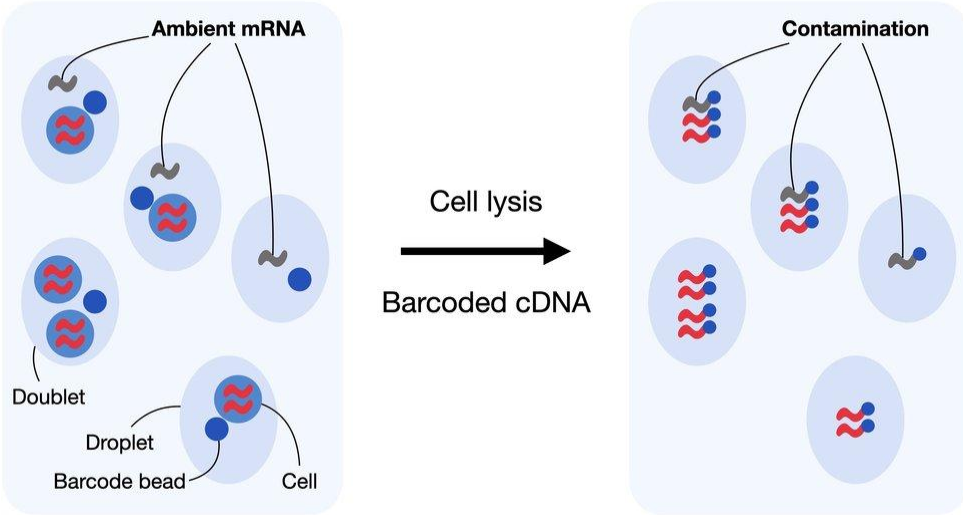
2700 → 2638 个细胞，只减少 62 个（2.3%）

AMBIENT RNA

环境 RNA：看不见的污染源

液滴里漂着的游离 mRNA，会被错误归到某个细胞名下

- 细胞裂解后，部分 mRNA 释放到液滴外的溶液中
- 这些游离 mRNA 会进入其他液滴
- 结果：某些高表达基因在所有细胞中都出现低水平信号
- 典型表现：某类细胞的标志基因在所有细胞里都有微弱表达
- 处理工具：
  SoupX、CellBender 等

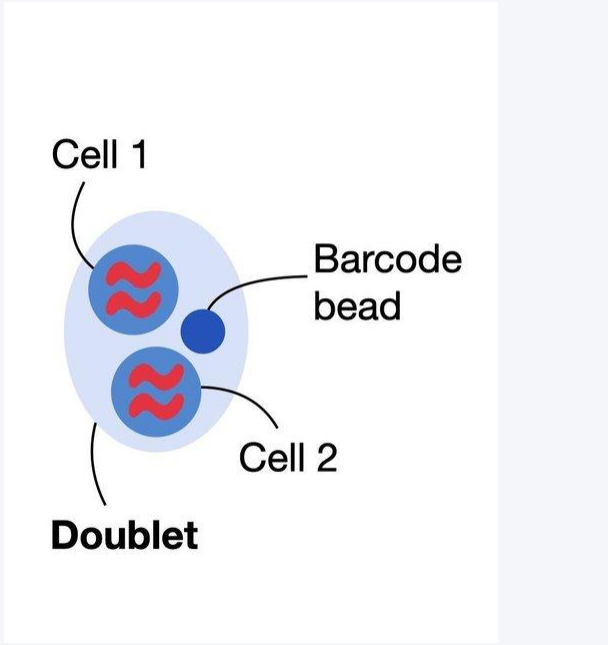


环境 RNA 污染的来源

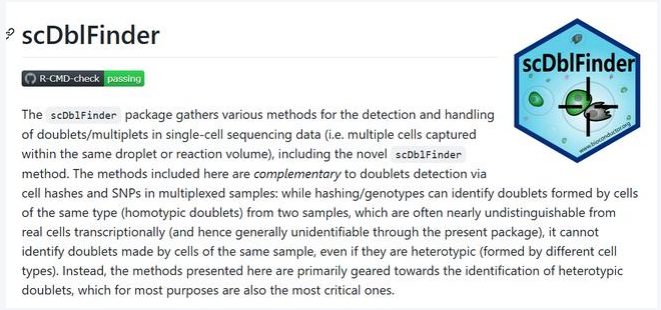
DOUBLETS

双细胞检测

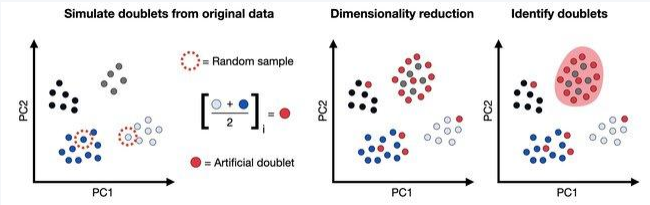
两个细胞被装进同一个液滴



双细胞的形成



检测工具：scDblFinder



检测算法原理：模拟→降维→识别

DOUBLETS

双细胞检测的常用工具与思路

双细胞不总是坏事，但必须先识别出来

scDblFinder

Bioconductor 包，用模拟双细胞与真实数据的邻域结构比较，速度快、准确率好。

DoubletFinder

sclet：RunDoubletFinder 封装。基于合成双细胞的 kNN 邻域打分。

Scrublet

Python 生态。通过模拟双细胞并比较转录组相似度打分。

判断原则

检测率通常设为 5%—10%，取决于实验的上样细胞密度。密度越高，双细胞比例越高。

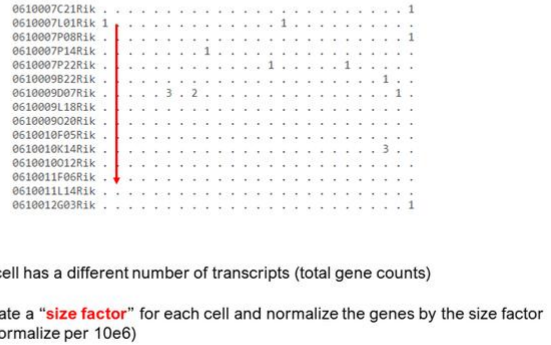
双细胞检测应该在建库质量评估阶段就纳入流程

STEP 3 · NORMALIZE

归一化：消除测序深度差异

不同细胞拿到的读段数不同，不归一化没法比

- 目标：让每个细胞的表达量处于可比较的尺度
- 常用方法：LogNormalize（除以总表达量再取对数）
- SCTransform：用负二项模型做方差稳定变换
- 取 scale.factor=10000 时，就是 CP10K
- 注意：归一化方法会影响后续的降维与聚类结果

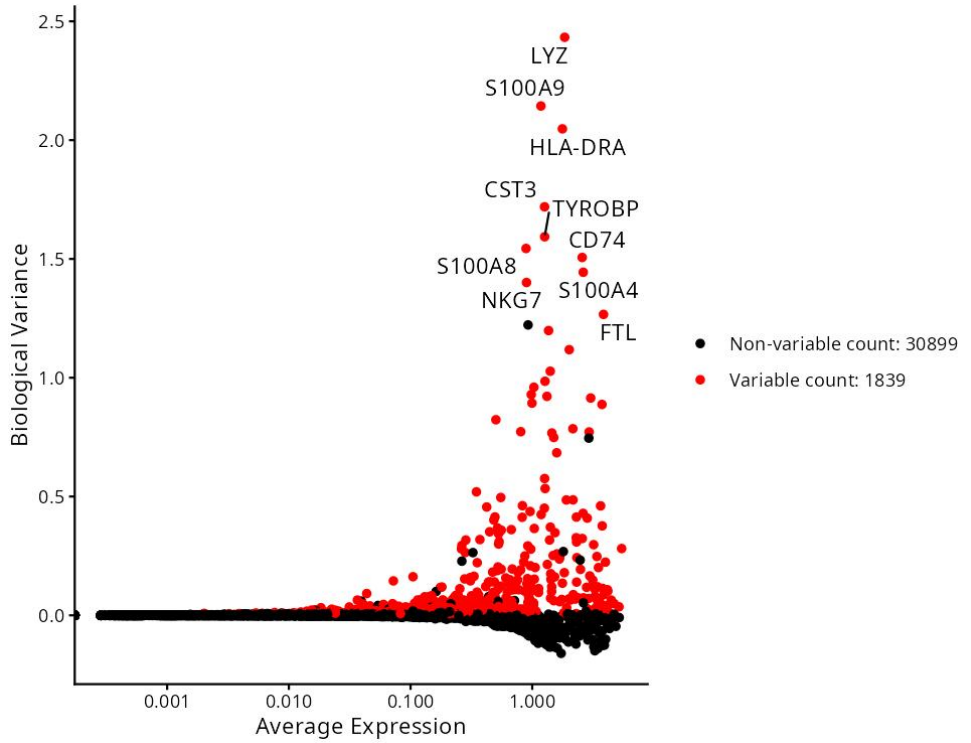


STEP 4 · HVG

高变异基因：挑出有信息的基因

多数基因在所有细胞里都没有变化

- 多数的基因在多数细胞里都是 0 值
- 真正有用的信息集中在少数变异大的基因里
- 选择具有生物学意义、能代表细胞间差异的基因
- 好处：降低维度、减少噪声、加速计算
- 通常选 2000 个左右，也可以按方法自动确定

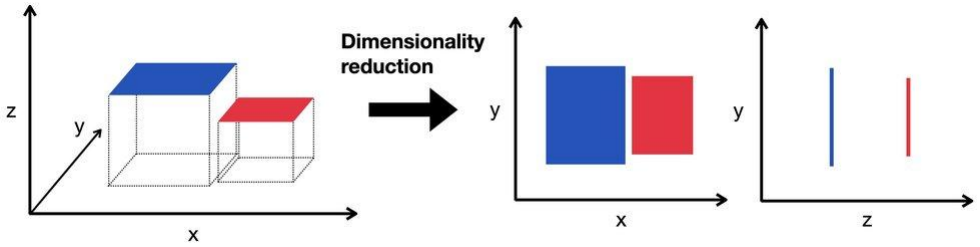


STEP 5 · DIMENSION REDUCTION

降维：把几万个基因压到几十个维度

高维空间里，距离本身就没有意义了

- 几万个基因构成的高维空间，无法直接可视化
- 高维空间中，所有点之间的距离趋于相等
- 降维的目的是找出真正驱动差异的方向
- 线性方法：PCA（用于后续聚类）
- 非线性方法：t-SNE、UMAP（用于可视化）

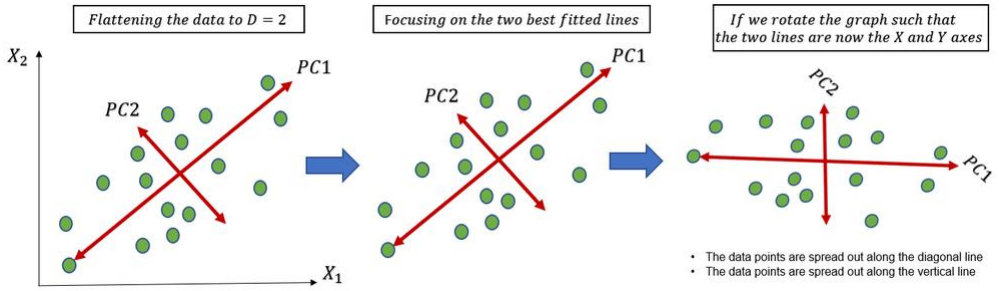


降维的动机

主成分分析：找到方差最大的方向

第一步是缩放，第二步才是分解

- 缩放数据：每个基因均值为 0、方差为 1
- 对缩放后的矩阵做奇异值分解
- 第一主成分是方差最大的方向，以此类推
- 每个主成分都是所有基因的线性组合
- 主成分本身没有生物学含义，但它的载荷可以解释



PCA 的几何意义

PCA 的两步操作

缩放与分解，顺序不能反

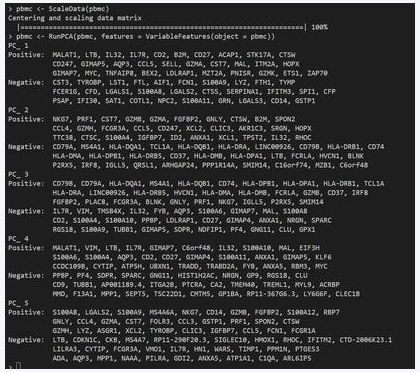
① ScaleData

对每个基因在细胞间做中心化、
标准化，消除量级差异，避免
高表达基因主导后续分析

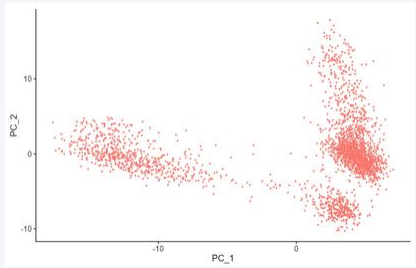
② RunPCA

基于高变基因做主成分分解，
将高维表达矩阵压缩到少数
主成分（PC），便于后续聚类

先缩放，再分解——顺序颠倒会让高表达基因淹没真实结构



运行 ScaleData 与 RunPCA



PCA 结果：主成分得分

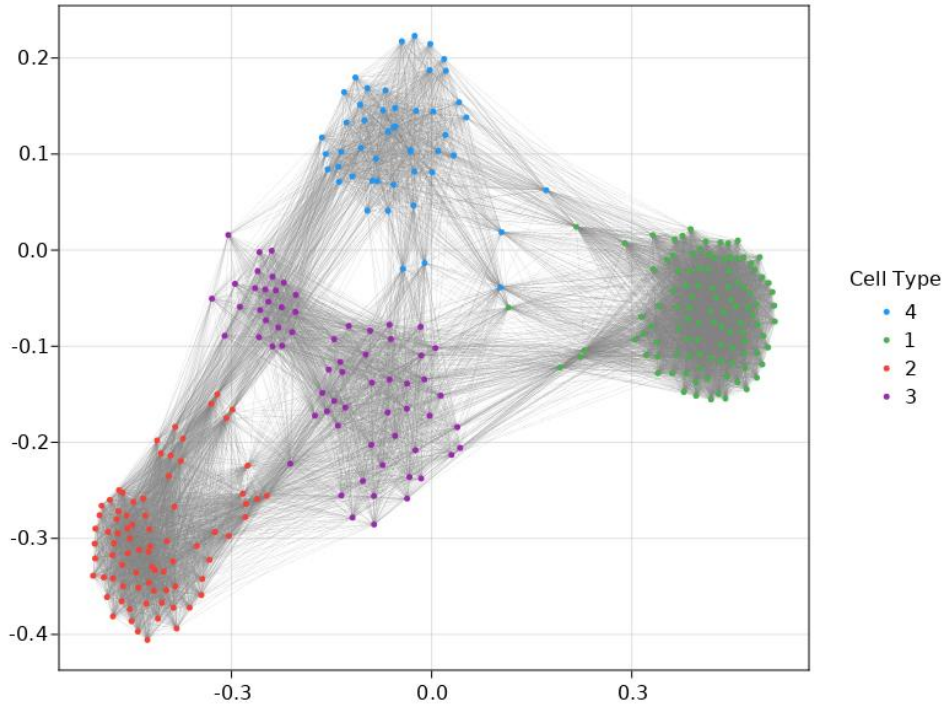
STEP 6 · CLUSTERING

表达模式相似的细胞归为一群

细胞聚类：图社区发现

Louvain 与 Leiden 是主流算法；sclet 用 Louvain

- 把细胞表示为图：节点是细胞，边是相似度
- 用社区发现算法把图切分成若干群
- Louvain：经典算法，速度快
- Leiden：Louvain 的改进版，保证社区内部连通
- sclet 聚类用 Louvain 默认 resolution 0.5



图社区发现算法

RESOLUTION

分辨率：决定分成几群

这是单细胞分析里最需要经验的一个参数

- 基于前 10 个主成分构建 KNN 网络
- 以分辨率为 0.5 进行聚类是常见起点
- 分辨率越高，产生的细胞类群越多
- 0.4—1.2 之间通常适用于约 3k 个细胞
- 细胞越多，分辨率通常设置越高

```
> pbmc <- FindNeighbors(pbmc, dims = 1:10)
Computing nearest neighbor graph
Computing SNN
> pbmc <- FindClusters(pbmc, resolution = 0.5)
Modularity Optimizer version 1.3.0 by Ludo Waltman and Nees Jan van Eck

Number of nodes: 2592
Number of edges: 93967

Running Louvain algorithm...
0%   10   20   30   40   50   60   70   80   90   100%
[----|----|----|----|----|----|----|----|----|----|
**************************************************|
Maximum modularity in 10 random starts: 0.8776
Number of communities: 8
Elapsed time: 0 seconds
>
```

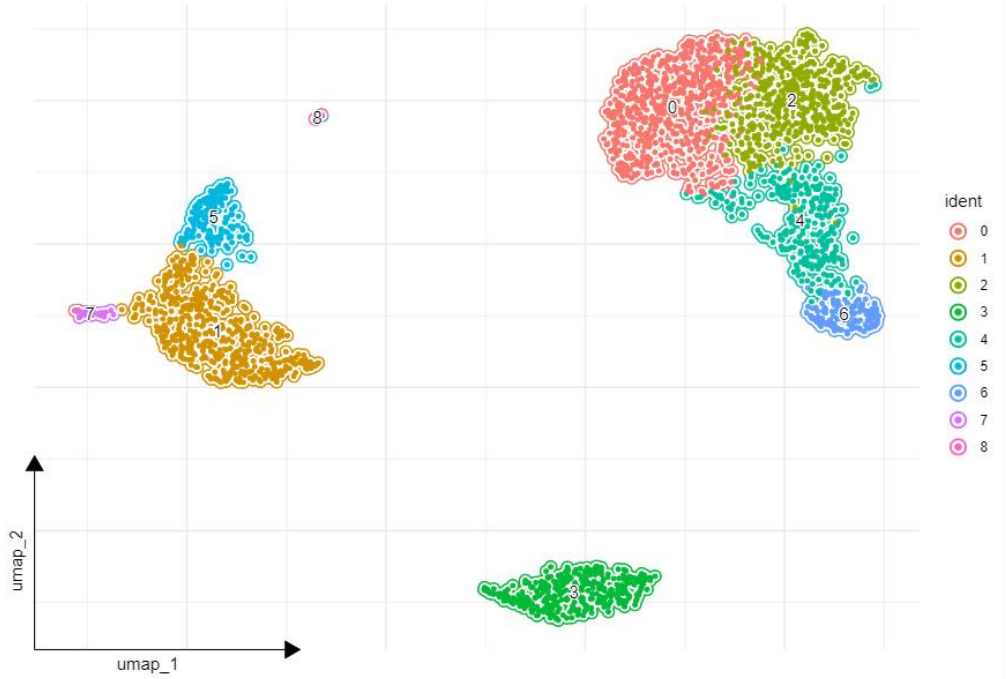
分辨率对聚类结果的影响

VISUALIZATION

非线性降维：只为可视化

t-SNE 与 UMAP 的坐标没有绝对含义

- t-SNE：擅长局部邻域结构，簇间距离不可比较
- UMAP：更好保留全局结构，大数据集下更快
- 重要提醒：图上两群的距离不代表相似度
- 群的大小也不代表细胞数量的真实比例
- 不要把 UMAP 坐标当作定量结果使用



UMAP 降维可视化示例

STEP 7 · ANNOTATION

细胞注释：把数字变成名字

聚类只是分组，注释才赋予生物学意义

通过标记基因注释

查已知的 marker，手工判断每个类群是什么细胞

通过表达谱参照注释

与参考数据集比对，自动匹配细胞类型

两者结合最可靠

先自动给出候选，再人工核对 marker

难点

有些类群没有明确 marker，
或表达谱介于两类之间

常见错误

把「未成熟亚群」当成新细胞类型

记录习惯

每个类群的判断依据都要写下来

注释的本质是「用已知解释未知」，必须有可核查的依据

MARKER GENES

鉴定标记基因

找每个类群相对其他类群显著高表达的基因

```
> markers <- FindAllMarkers(se, group.by = 'label', only.pos = TRUE)
Using 'logcounts' for marker testing instead of active layer 'scaled'.
Calculating markers for all clusters using presto...

> dim(markers)
[1] 6315   10

> head(markers, 3)
       pval      padj  avg_log2FC pct.1 pct.2 cluster gene
CCL5  8.0e-240  2.6e-235   3.16    0.966 0.216    1    CCL5
GZMK  5.5e-179  8.9e-175   1.42    0.546 0.046    1    GZMK
NKG7  3.3e-169  3.6e-165   2.51    0.882 0.208    1    NKG7
```

FindAllMarkers() 输出（PBMC3k，9 个类群）

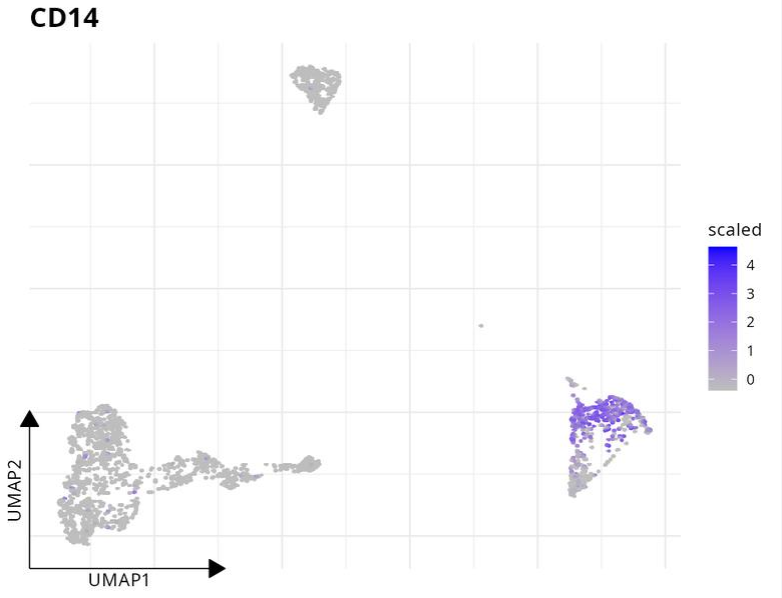
类群	top gene	log2FC	pct.1	pct.2
CD8 T	CCL5	3.16	97%	22%
B	CD79A	2.70	93%	4%
Naive CD4 T	LTB	1.55	98%	64%
FCGR3A+ Mono	FCGR3A	2.34	92%	13%
NK	GZMB	3.47	97%	7%
Memory CD4 T	LDHB	1.17	93%	60%
CD14+ Mono	S100A9	4.16	100%	23%
DC	FCER1A	2.23	86%	1%
Platelet	GP9	3.14	92%	0%

每个类群表达最强的 top 1 marker（真实计算）

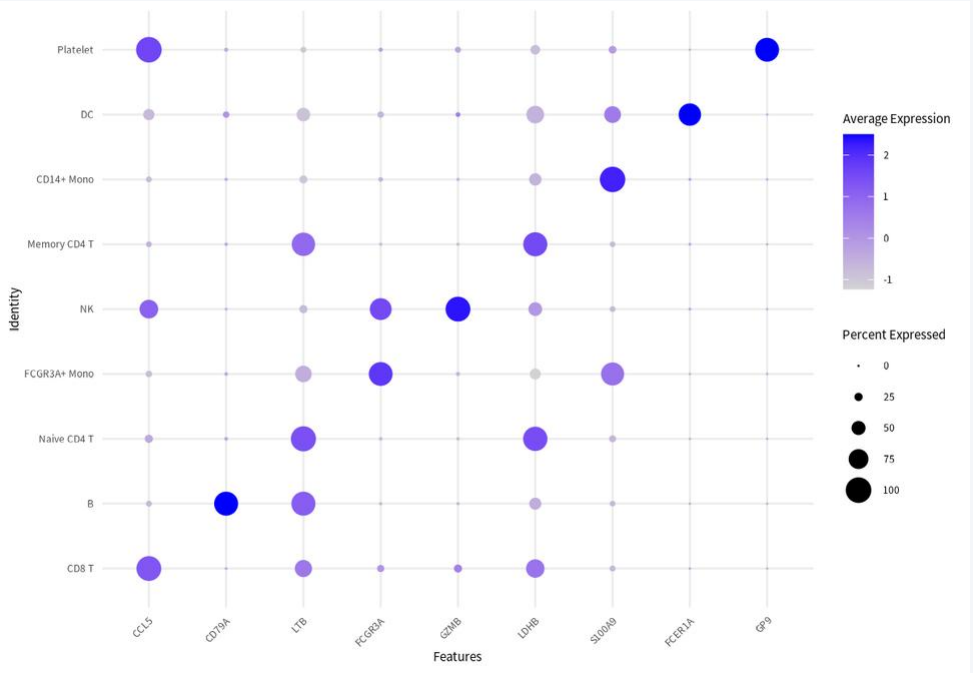
MARKER GENES

查看基因在不同类群中的表达

单个基因看分布，多个基因看气泡图



CD14 在 UMAP 上的表达（真实数据）



sc_dot()：9 个类群 × top marker（真实计算）

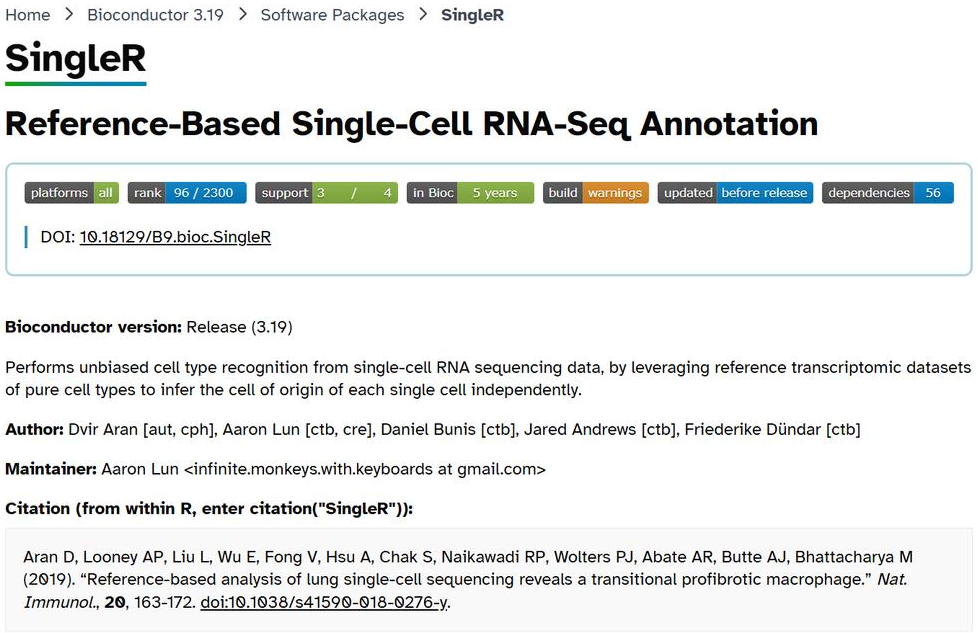
AUTO ANNOTATION

通过参考集进行自动注释

拿已知图谱当参照，快速给出候选类型

- 常用参考：
  Human Cell Atlas、
  已发表图谱、免疫参考集
- 方法：找每个类群与参考中最相似的细胞类型
- 优点：快，
  尤其适合常规组织
- 缺点：参考里没有的类型
  无法识别，依赖参考质量

```
pbmc <- RunSingleR(pbmc, ref = hpca, labels = hpca$label.main)
结果写进 colData 的同时登记到账本：
get_annotation(pbmc) / get_mapping(pbmc)
```



Home > Bioconductor 3.19 > Software Packages > **SingleR**

SingleR

Reference-Based Single-Cell RNA-Seq Annotation

platforms all | rank 96 / 2300 | support 3 / 4 | in Bioc 5 years | build warnings | updated before release | dependencies 56

DOI: 10.18129/B9.bioc.SingleR

Bioconductor version: Release (3.19)

Performs unbiased cell type recognition from single-cell RNA sequencing data, by leveraging reference transcriptomic datasets of pure cell types to infer the cell of origin of each single cell independently.

Author: Dvir Aran [aut, cph], Aaron Lun [ctb, cre], Daniel Bunis [ctb], Jared Andrews [ctb], Friederike Dündar [ctb]

Maintainer: Aaron Lun <infinite.monkeys.with.keyboards at gmail.com>

Citation (from within R, enter citation("SingleR")):

Aran D, Looney AP, Liu L, Wu E, Fong V, Hsu A, Chak S, Naikawadi RP, Wolters PJ, Abate AR, Butte AJ, Bhattacharya M (2019). "Reference-based analysis of lung single-cell sequencing reveals a transitional profibrotic macrophage." *Nat. Immunol.*, **20**, 163-172. doi:10.1038/s41590-018-0276-y.

自动注释的原理

ANNOTATION · FOUNDATION MODELS

单细胞基础模型

把表达谱当成一种「语言」来预训练，给注释一个更强的起点

核心思想

在海量单细胞数据上做自监督预训练，学出通用的细胞表征

代表模型

scGPT、Geneformer、Nicheformer 等

能做什么

细胞类型注释、基因扰动预测、跨数据集迁移、零样本任务

为什么有用

标注数据稀缺，预训练可以从无标注数据中获益

注意

模型输出依赖训练数据的组织与物种分布，跨域使用要谨慎验证

实用建议

把基础模型当作「候选生成器」，结论仍需 marker 与实验验证

基础模型不是替代分析流程，而是给流程提供一个更强的起点

PART 05

细胞有了名字之后

05

sclet 的下游分析：从「有哪些细胞」到「它们在做什么」

- **差异与富集：RunDEtest → RunEnrichment**
  这一群凭什么单独成军，它们在做什么
- **身份与参考：RunSingleR / RunReferenceWorkflow**
  不靠手查 marker，让参考图谱自己投票
- **轨迹与速率：RunTrajectoryWorkflow / RunVelocity**
  静止的一张快照，怎么连成一段时间
- **通讯、打分与聚合：RunCCI / RunGeneSetScoring / RunSuperCell**
  细胞之间怎么说话，一套程序开没开

每一步都记进账本：Status() 能回放，sclet_copilot() 接着往下分析

DOWNSTREAM MAP

先问一个问题，再挑一个函数

五个问法对应八个函数；挑错函数，参数调得再细也没用

① 谁和谁不一样?

RunDEtest() → RunEnrichment()

差异基因列表，再由富集翻成通路
padj 定显著，pct.1/pct.2 定特异

② 这群细胞是什么?

RunSingleR() / RunReferenceMapping()

自动注释，或者让参考图谱投票
结果落进 colData，随时回看

③ 它们怎么变过去?

RunTrajectoryWorkflow()

主轨迹加拟时间，排出分化顺序
速率要剪接数据，另一条路

④ 它们之间怎么交流?

RunCCI()

三种后端：CellChat / CellPhoneDB / NicheNet
输出统一的配体—受体表，get_cci() 取回

⑤ 程序开没开、细胞够不够多?

RunGeneSetScoring() / RunSuperCell()

打分：这一群有没有打开某套程序
聚合：相似细胞并成元细胞再分析

函数答不上来的问题，参数再换也答不上来——先写下问题，再挑函数

DIFFERENTIAL EXPRESSION

差异分析的产出是一张排序表

RunDEtest() 一次算完 9 群，给出 10254 行 marker

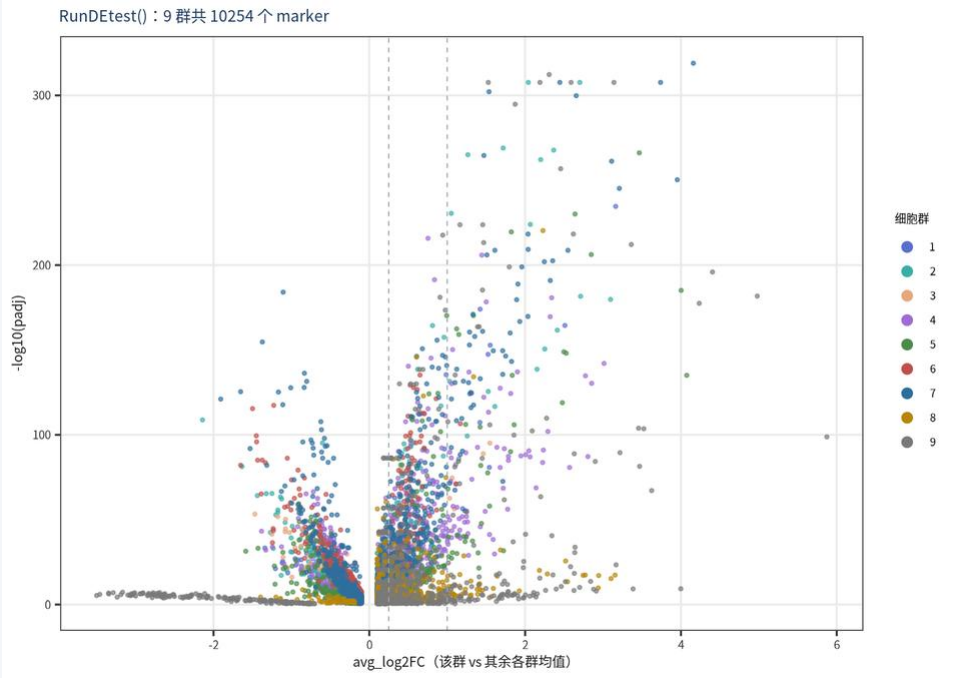
```
# 只找正向 marker，先卡两道阈值
sce <- RunDEtest(sce, only.pos = TRUE,
                 min.pct = 0.25,
                 logfc.threshold = 0.25)
d <- get_detest(sce)$artifacts$result
head(d[order(d$padj),
  c("cluster","gene","avg_log2FC","pct.1","pct.2")])
```

9 群共 10254 行，值得细看的只有 587 行

padj < 0.05 有 9296 行，再加 |log2FC| > 1 只剩 587 行

群	marker	log2FC	pct.2
7	S100A8	3.74	0.131
5	GZMB	3.47	0.068
2	CD79A	2.70	0.041
6	RPS27	0.65	0.992

padj 约等于 0 不等于特异：RPS27 在其余 99.2% 的细胞里也表达



RunDEtest() 的火山图：虚线是 log2FC 阈值 0.25 与 1

第 9 群只有 13 个细胞，点全压在底部——样本太少就没有证据

FUNCTIONAL ENRICHMENT

富集把基因表翻译成生物学过程

RunEnrichment() 接上一步的 marker 表，给出 3356 行 GO 条目

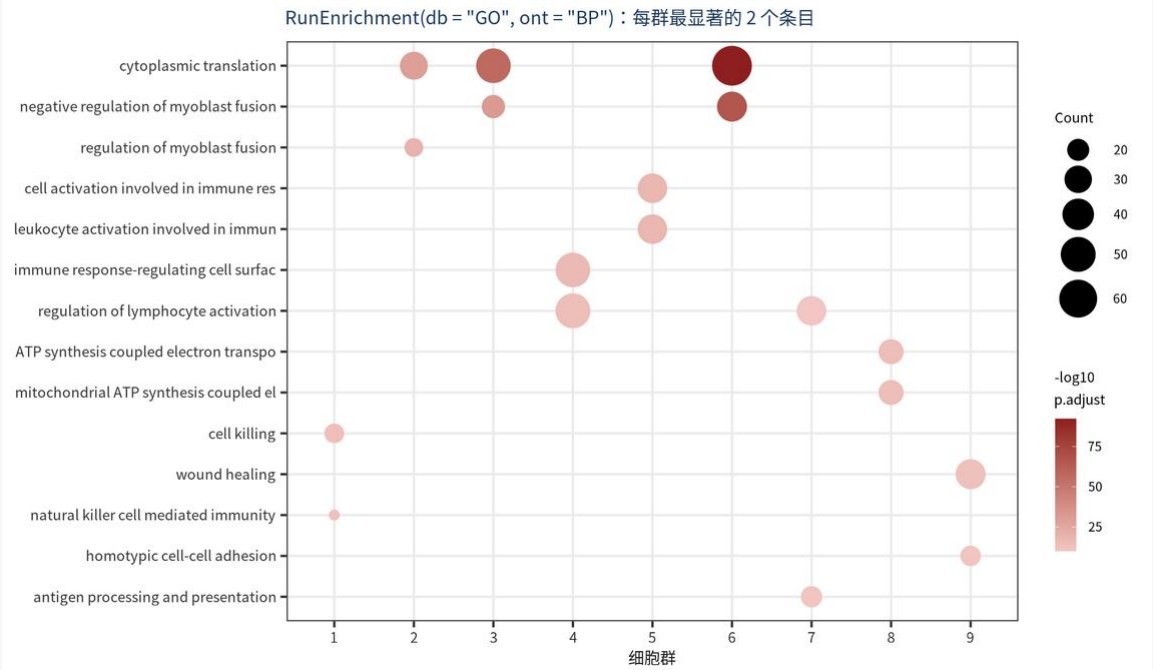
```
# 输入是 RunDEtest() 存下的 marker 表
# 后台默认就是 GO 的生物学过程（BP）
sce <- RunEnrichment(sce, db = "GO",
      keyType = "SYMBOL",
      orgDb = "org.Hs.eg.db")
e <- get_enrichment(sce)
EnrichmentPlot(sce, showCategory = 5)
```

3356 行条目，排名第一之后要先存疑

- 第 6 群 67 基因命中 cytoplasmic translation
- 第 8 群 25 基因命中 ATP 合成与电子传递
- 第 1 群 cell killing、第 7 群抗原加工与递呈

第 6 群第 2 名是 myoblast fusion，
但 36 个基因全是核糖体蛋白，与肌肉无关

富集排名会被注释库带偏，回看基因列表再下结论



每群最显著的 2 个 GO 条目（条目名按 38 字符截断）
点越大命中基因越多，颜色越深 p.adjust 越小

REFERENCE MAPPING

参考映射把细胞放进别人的坐标系

RunReferenceMapping() 三种后端：SingleR、KNN、Symphony

```
# 切出 500 个细胞当参考，其余当查询
idx <- sample(seq_len(ncol(sce)), 500)
ref_sce   <- sce[, idx]
query_sce <- sce[, -idx]
query_sce <- RunReferenceMapping(
  query_sce, ref = ref_sce, labels = "label",
  method = "KNN", layer = "logcounts", k = 5)
ProjectionPlot(query_sce, ref_sce)
```

映射干不干脆，看行比例落在哪里

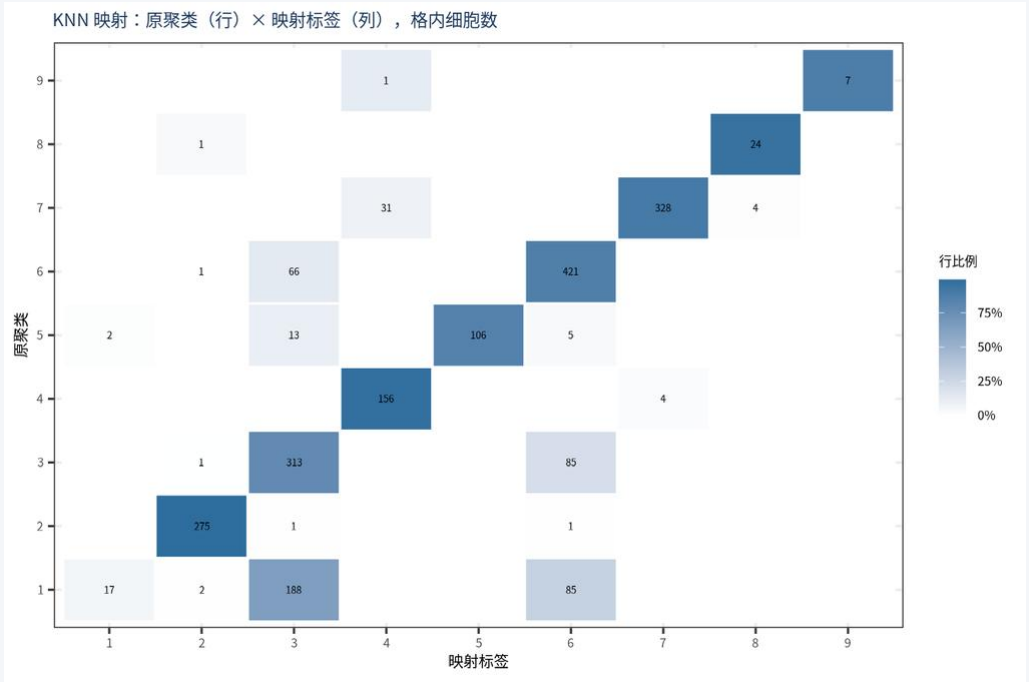
第 2 群 99.3%、第 4 群 97.5% 一对一落回原群

第 7 群 90.4%，第 8 群 96.0%

第 1 群只有 64.4%——188 落到 3、85 落到 6

参考取自同一份数据，相似是循环论证；

真参考必须来自外部：celldex、HCA、CIMA



原聚类 × KNN 映射标签，格内是细胞数

整行集中在一个格子里，说明这群在参考中找得到对应

TRAJECTORY

静止的一张快照，也能排出先后

RunSlingshot() 把 9 个聚类连成 4 条主线

```
# 封装版：一条命令跑完主轨迹
sce <- RunTrajectoryWorkflow(sce, group = "label",
  reduction = "UMAP", run_diffusion_map = FALSE,
  run_slingshot = TRUE, name = "traj")
# 直接调 Slingshot 也可以
sce <- RunSlingshot(sce, group = "label",
  reduction = "UMAP")
```

4 条主线，全部落在 colData 里

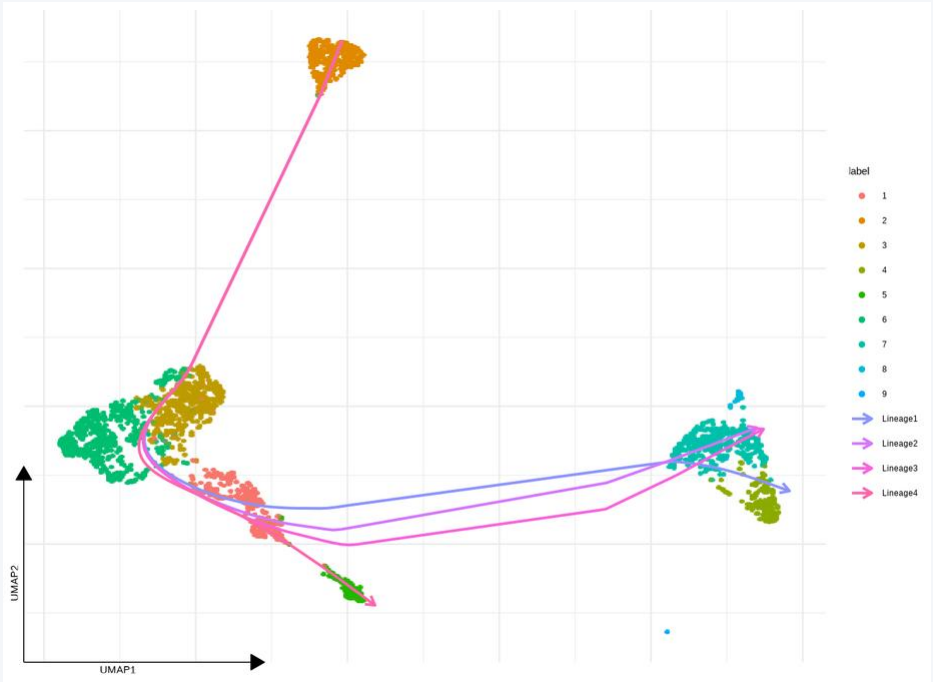
colData 多出 4 条主线拟时间与 slingBranchID

has_trajectory() 立刻变成 TRUE

Status() 记下 traj_slingshot

主线是拿聚类当输入算出来的：
换一次聚类，就会换一条主线

轨迹推断的是假设，不是观测到的过程



plot_lineage()：4 条主线叠在同一张 UMAP 上
线是算法连的，不代表细胞真的沿着线迁移

CELL–CELL COMMUNICATION

细胞之间怎么说话

RunCCI() 一个接口接三种后端，输出同一张配体—受体表

```
# 后端三选一，输出格式统一
sce <- RunCCI(sce, method = "CellChat",
  group = "CellType", layer = "logcounts",
  name = "cellchat_main", keep_object = TRUE)
cci_df <- get_cci(sce)
plot_cci_arrow(sce, cell_a = "Ductal",
  cell_b = "Endocrine", group = "CellType")
```

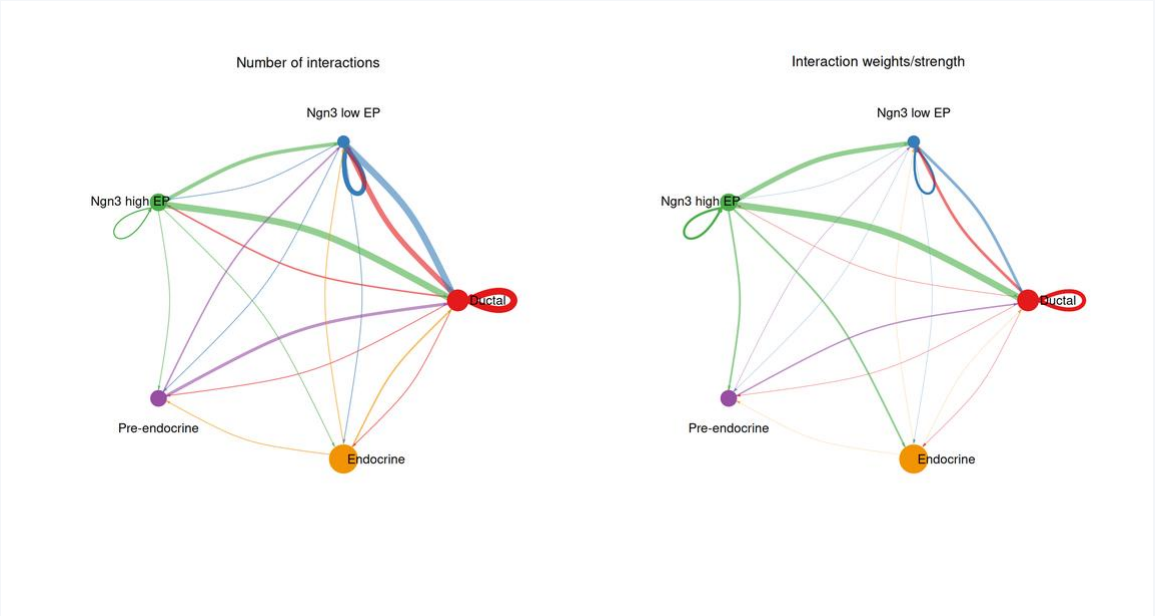
三个后端，各有擅长

- CellChat：互作数量与强度，圆图看全局
- CellPhoneDB：配体—受体复合物层面的检验
- NicheNet：指定发送与接收群，给出靶基因

p 值来自置换检验：CellChat 检验互作概率，CellPhoneDB 检验配体—受体复合物的均值

三个后端都归到同一张表，get_cci() 取回

互作由表达量推断，不等于细胞真的在通讯



CellChat 圆图：连线粗细是两个细胞群之间的互作数量

数据来自 sclet 文档的 pancreas 演示集

RNA VELOCITY

速率要的是剪接数据

RunVelocity() 的前置条件，写在 Status() 的健康检查里

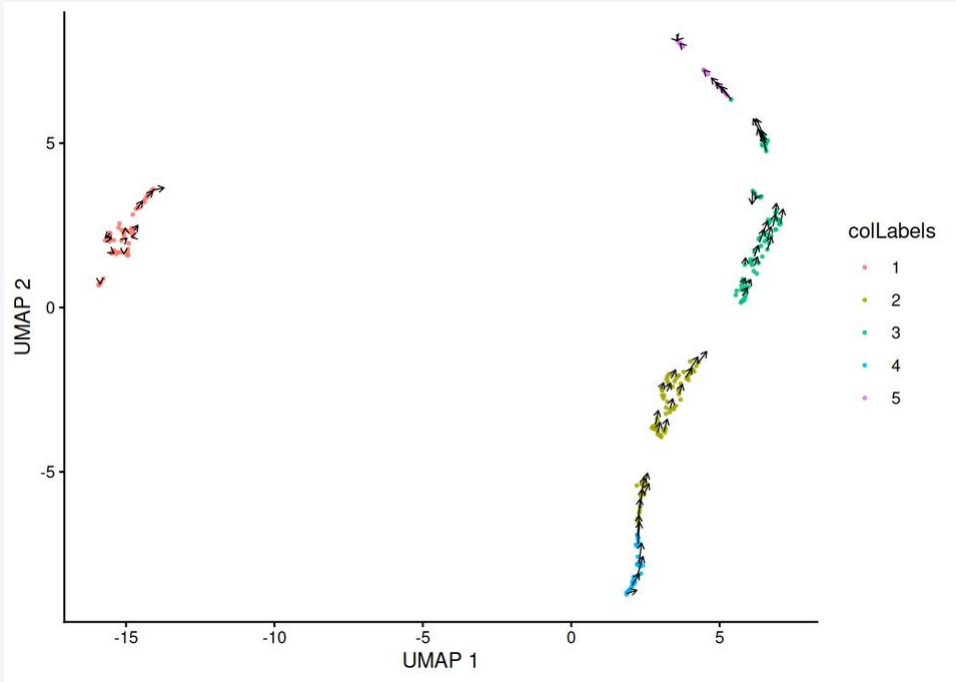
```
Status(sce)$health$has_spliced_assay   # FALSE
Status(sce)$health$has_unspliced_assay  # FALSE
# 这两项为 FALSE，速率一步都不该开始
# 拿到剪接计数以后：
sce <- RunVelocity(sce, mode = "stochastic")
plot_velocity(sce, reduction = "UMAP")
sce <- RunCellRank(sce)
```

为什么这里必须停

- 10x 常规 3' 建库只读 PolyA 尾附近一段
- 剪接与未剪接的区分要靠内含子读段
- 要 velocyto 或 kallisto bustools 单独产出

前提是转录动力学恒定、细胞处在同一条流形上

没有剪接数据就去跑速率，
算出来的箭头没有解释力



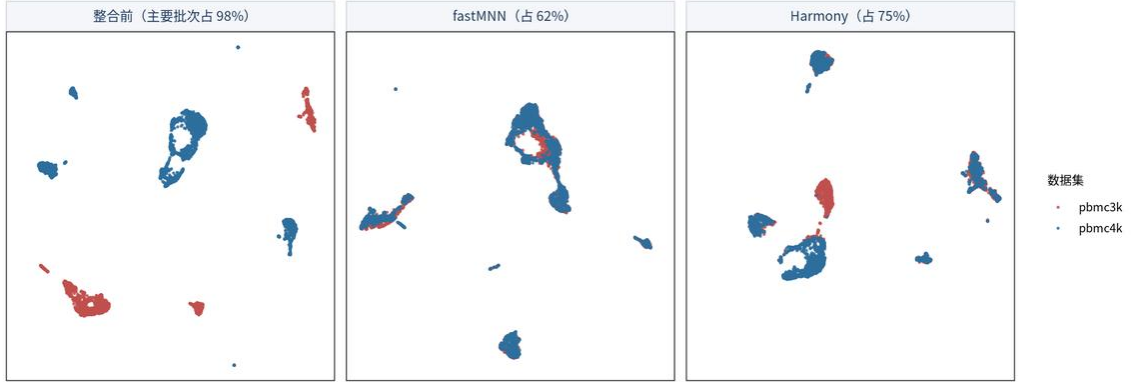
plot_velocity()：箭头从当前状态指向预测的下一步
sclet 文档用带剪接计数的演示数据跑出的箭头

INTEGRATION

去掉批次，留住生物学

RunIntegration() 三种后端：fastMNN、Harmony、scVI

```
# 两份数据先合到一起
combined <- sce_merge(list(pbmc3k = a, pbmc4k = b))
rm_batch <- RunIntegration(combined,
  method = "fastMNN", batch = "dataset",
  correct.all = TRUE)  # 才有全基因校正矩阵
reducedDims(rm_batch)$PCA <- NULL  # 丢掉未校正的 PCA
rm_batch <- RunPCA(rm_batch, layer = "corrected")
rm_batch <- RunUMAP(rm_batch, dims = 1:10)
```



按数据集着色：整合前两批各自成块，整合后同一群里两批都在

pbmc3k 2638 细胞 + pbmc4k 3730 细胞，各做同一套 QC 与归一化

同一群里有没有两个数据集

- 整合前：12 个群，主要批次平均占 98%，0 个群混批
- fastMNN：9 个群，平均占 62%，9 个群两批都有
- Harmony：10 个群，平均占 75%，5 个群两批都有

一个群里两批都有，才叫整合到位

判据落在同一细胞类型上，不是全局混匀

这一步最容易漏掉

fastMNN 默认只对高变基因子集给出校正表达值

要在校正后的表示上重做降维与聚类

SCLET

sclet 把单细胞分析收进一个入口

SingleCellExperiment 内核 + 状态契约 + 多种分析后端

一个分析对象

SingleCellExperiment

表达矩阵 · 降维 · 注释

结果层 · 参数 · 分析账本

对象自己知道“做到哪一步”

统一入口

Read10X() · RunXxx() · get_*()

状态契约

Status() · has_*() · provenance

多后端封装

把 R / Python 方法接到同一对象

可继续扩展

Scanpy · scVI · 空间与多组学

sclet 的价值不在于替代底层方法

而在于让不同方法围绕同一份可追溯对象协同工作，成为分析的总入口

IN DEVELOPMENT

面向 AI 的分析账本仍在开发

sclet_copilot() 的目标是让模型读懂结构化分析记录

```
# 标准流程 7 条，之后又跑了差异与轨迹，共 9 条
Status(sce)$n_commands       # 9
Status(sce)$last_command
  # "RunTrajectoryWorkflow"
sclet_copilot(sce,
  "聚类参数合理吗？会过度整合吗？")
AuditAnalysisChain(sce,
  features = top_markers, raw_layer = "counts")
```

对象自带账本：每条命令的参数与时间都在里面

↓

开发目标：把账本连同问题一起交给模型

↓

目标：保留分析链与证据引用，并支持回查

当前定位：研究中的 AI 接口，不是现成的课堂功能

已有接口草案，仍需验证回答质量与跨后端稳定性

确定性分析仍以 Status()、get_*()、has_*() 为准

未来目标是让 AI 读取账本，而不是替代分析者做判断

SPATIAL TRANSCRIPTOMICS

位置是单细胞拿不到的那一列

单细胞给出「有哪些细胞」，空间给出「它们在哪」

① 组织解离
拿到细胞类型清单，位置信息全部丢失

↓

② 原位捕获
保留坐标，但一个 spot 是一小团细胞的混合表达

↓

③ 把类型放回坐标
把单细胞解出的类型分回每个 spot，位置重新有了身份

单细胞答不了的那部分

- 解离这一步就把位置信息洗掉了
- 同一个类型，换个位置可能是另一种状态
- 细胞之间的邻接关系，单细胞矩阵里没有
- 组织边界与区域，同样只在坐标上看得出来

分析对象从「细胞 × 基因」扩到「位置 × 细胞类型」
同一个细胞类型，在不同邻域里的行为可能完全不同

单细胞给名单，空间给位置——下一步把名单对回地图

变化的是坐标系与数据形态，判据仍然是那一套

PART 06

位置即功能

06

为什么单细胞还不够？从生命的起源说起

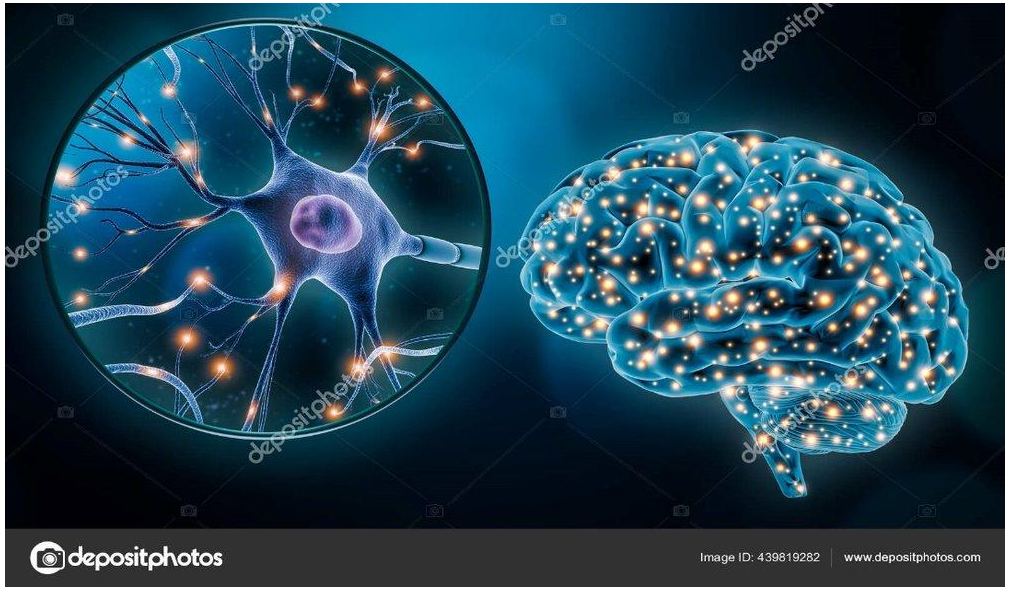
- 40 亿年前：遗传物质与蛋白出现
- 35 亿年前：细胞膜把生命分隔开
- 约 10 亿年前：多细胞生物开始分化
- 位置，是细胞发挥作用的场所

DEFINITION

空间转录组：给分子发一个门牌号

基因表达数据 + 细胞在组织中的空间位置

- 一种结合基因表达数据与空间位置信息的技术
- 为理解细胞如何在组织环境中相互作用提供新视角
- 不同类型的神经细胞在特定位置执行特定功能
- 不知道位置，就无法理解它们如何相互作用
- 也就无法理解思考、感觉与行动背后的机制

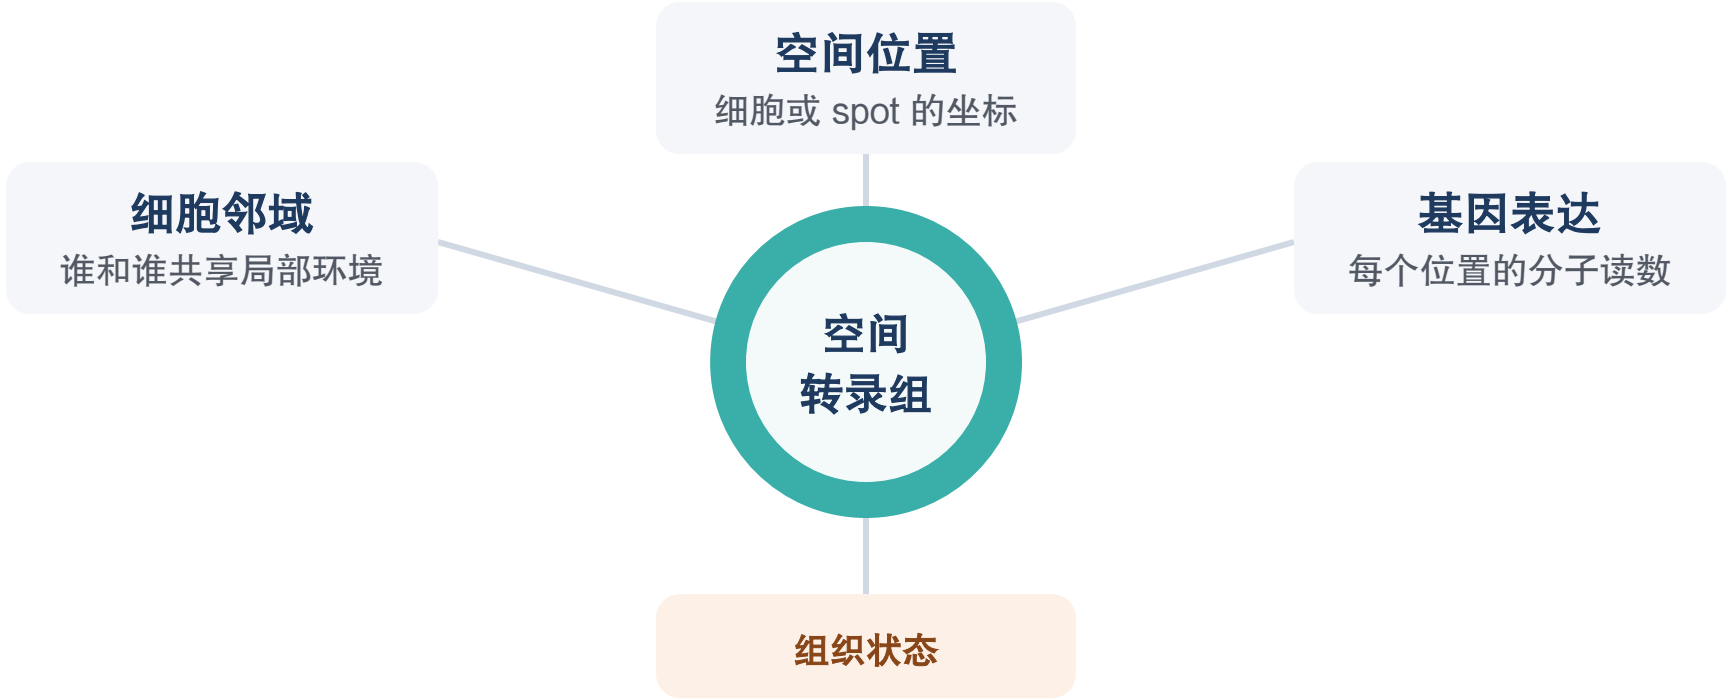


空间转录组的概念

THREE ELEMENTS

空间转录组：三件事缺一不可

位置、表达与邻域共同解释一个组织状态



只有把“在哪里、表达什么、和谁相邻”放在一起，组织才真正可解释

LANDSCAPE

空间组学技术，归根到底在回答两个问题

在哪里测到？测到的是谁？两条主线由此分开

主线一：直接读出空间

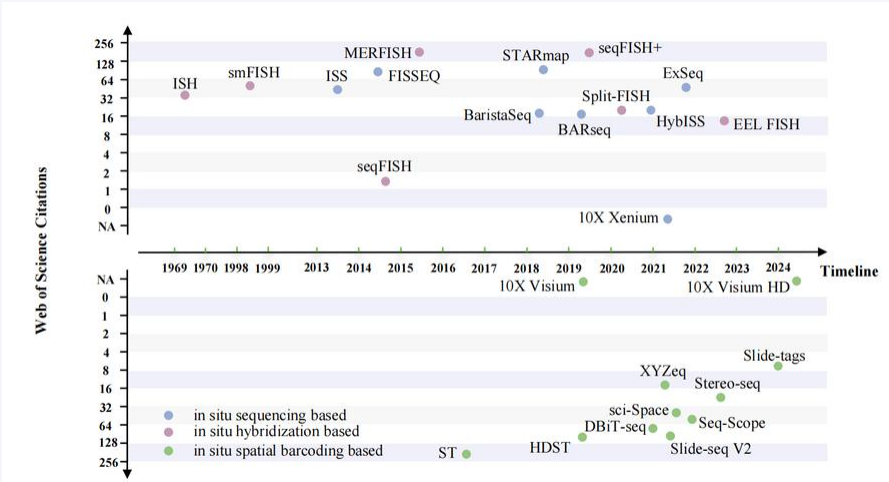
原位杂交成像、原位测序

先保留位置，再读出分子信号

主线二：先捕获，再定位

原位捕获、显微切割

用捕获单元或切割区域承载表达信息



技术谱系：分辨率、通量与基因覆盖各有取舍

资料参考：Wang Q et al. 2024, The Innovation 5(4):100637

DOI: 10.1016/j.xinn.2024.100637

COMPARE

先选一边：看清形态还是测全转录组

这是选技术时第一个要回答的问题

维度	基于成像	基于测序
分辨率	单细胞或亚细胞水平	通常难以达到单细胞水平
可视化	直接通过显微镜观测	需要数据处理后可视化
基因数量	检测数量通常有限（数十到数千）	全转录组范围检测，不依赖预设探针
易用性	探针面板需预先设计，灵活性较低	商业化程度高，分析相对成熟
成本	探针设计成本高，单次检测基因数受限	单次可测全转录组，单位信息成本低
典型用途	验证假设、精细定位少数靶标	生成假设、探索性研究

基于测序的原位捕获更适合「生成假设」的探索类研究

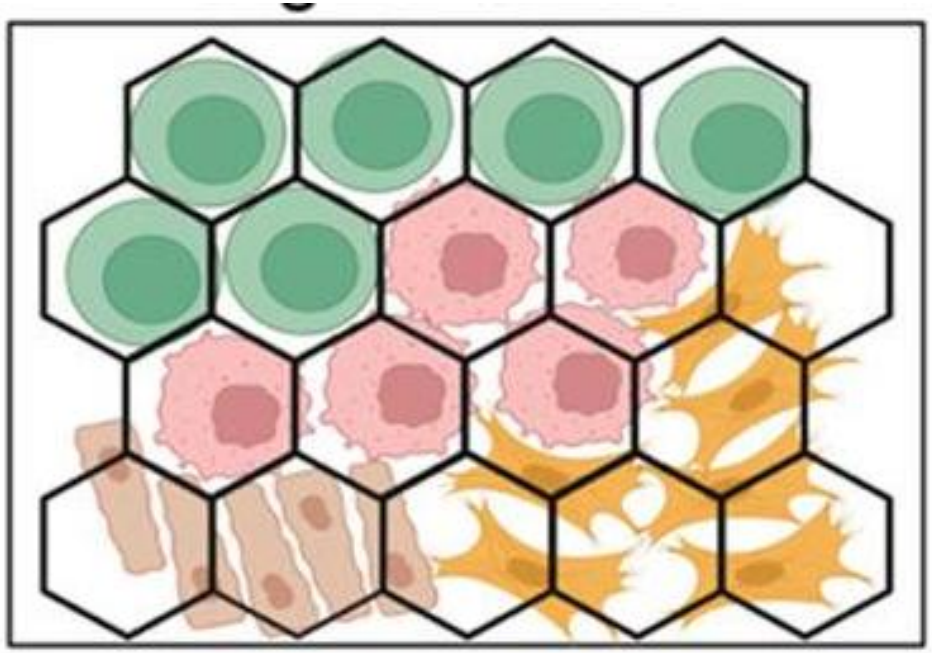
TWO ROUTES

原位捕获技术的两条路线

路线不同，升级方式也不同

- 路线 1：基于 RNA 的空间定位技术
- 代表：10x Visium HD、Stereo-seq
- 升级方式：提升芯片上捕获单元的分辨率与密度排列

- 路线 2：基于细胞的空间定位技术
- 代表：SeekSpace、Slide-tag
- 升级方式：走向空间上的单细胞多组学



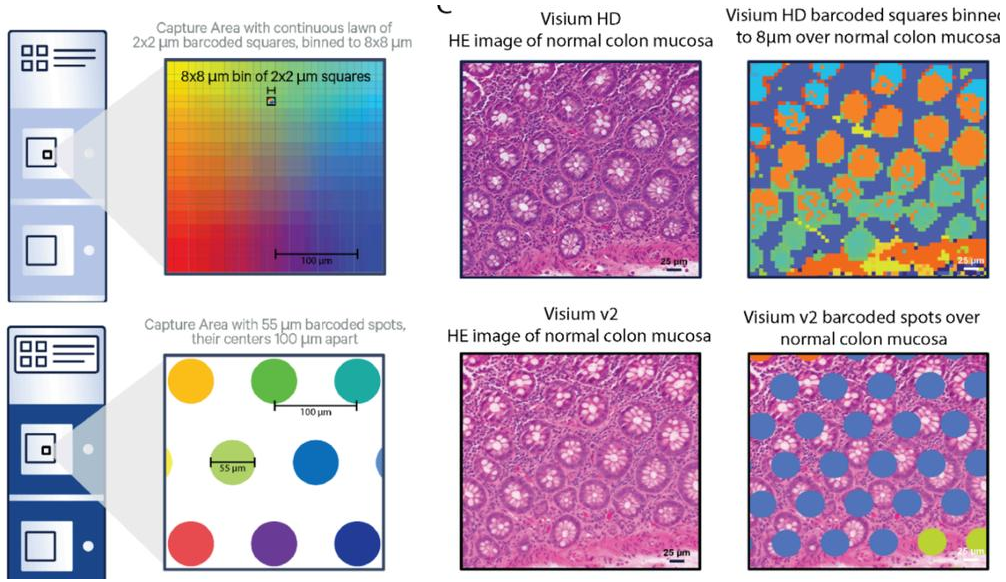
两条技术路线的分类

ROUTE 1

路线 1：基于 RNA 的空间定位

通过透化到芯片上的 RNA 信息，推测该位置的细胞身份

- 透化组织，使 RNA 就近沉降到芯片的 spot 捕获单元
- 扩增建库测序，解析每个 spot 的基因表达
- 局限：单个 spot 通常包含多个细胞，分辨率受捕获单元尺寸限制
- spot 内的引物结合 RNA 信息
- 基于 RNA 表达信息反推该位置细胞的身份



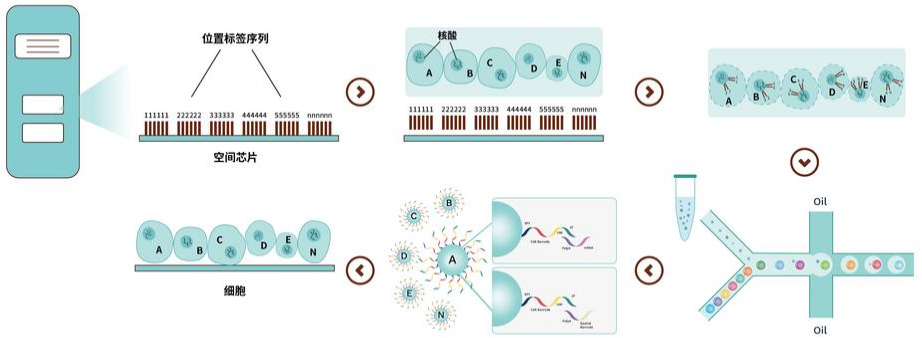
路线 1 的工作流程

ROUTE 2

路线 2：基于细胞的空间定位

直接以细胞本身为检测单元做反向位置标记

- 芯片位置标签信息反向标记到细胞核
- 对切片上的组织制备细胞核悬液
- 执行常规的单细胞转录组捕获流程
- 细胞 barcode 同时识别细胞身份与位置信息
- 优势：无需额外的单细胞数据辅助，直接溯源空间定位



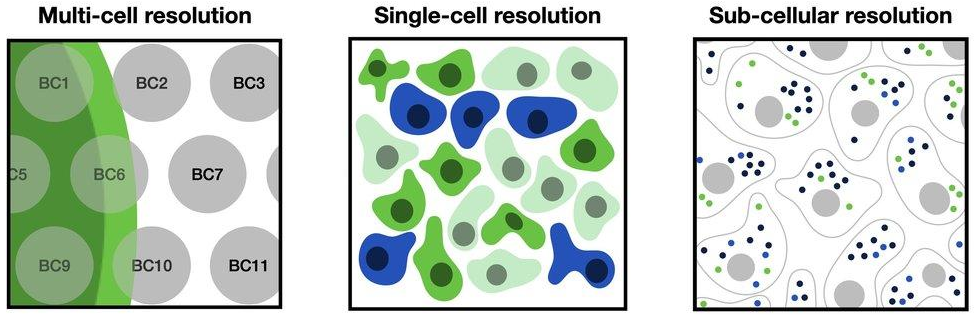
路线 2 的工作流程

RESOLUTION

分辨率不是越高越好

从组织到亚细胞，不同技术落在不同尺度上

- 组织级：几百微米，只能看区域整体
- spot 级：55 μm（Visium）→ 2 μm（Visium HD）
- 单细胞级：Xenium、MERFISH Stereo-seq（binning 重组）
- 亚细胞级：原位测序与成像
- 分辨率越高，单位面积的数据量越大，分析难度也越高



空间技术的分辨率尺度

DECISION

哪种技术适合我的研究

按顺序问自己四个问题

问题一

我要看全转录组，还是只看少数已知靶标？

问题二

我需要单细胞分辨率，还是区域级分辨率就够？

问题三

组织能否解离？样本是否珍贵、不可分割？

问题四

我是想验证已有假设，还是探索性地生成新假设？

经验法则

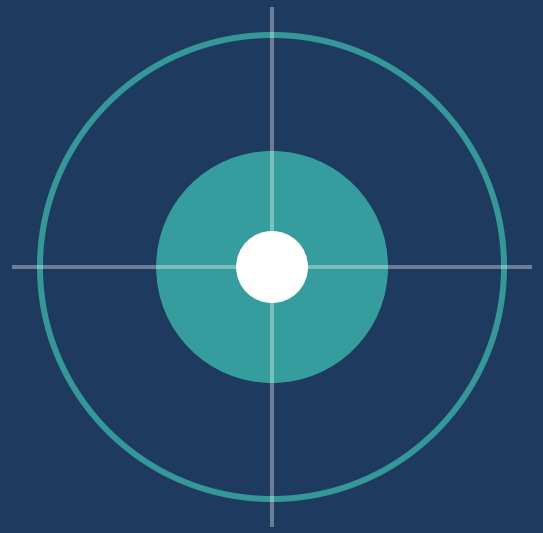
探索性研究优先基于测序，验证性研究可用基于成像

成本考虑

单次实验成本高，建议先做小规模预实验确认方案

技术选择是研究设计的一部分，不是实验开始前的临时决定

PART 06 · BIOLOGICAL QUESTIONS



地图打开之后

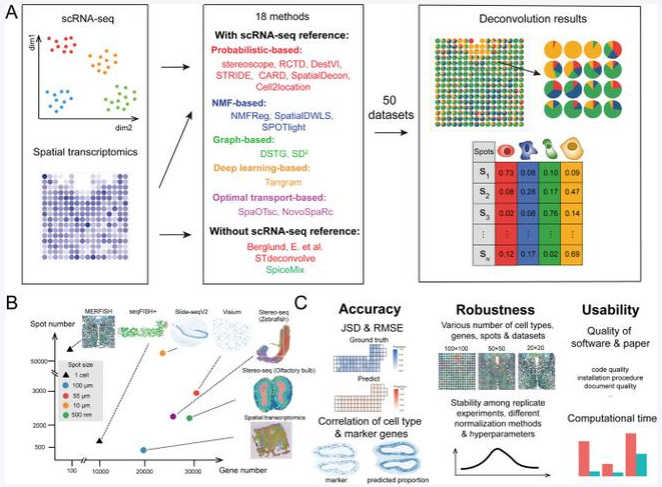
空间信息，究竟改变了哪些生物学问题？

先看问题，再决定需要哪一种分析

WHY PAIR WITH SINGLE CELL

一个 spot 里面可能有谁?

空间表达给了我们位置，却不一定直接给出细胞身份



单细胞参考图谱可以帮助解释混合 spot

为什么要接上单细胞?

空间数据：表达发生在哪里

单细胞数据：有哪些细胞状态

目标：解释每个位置由谁贡献

单细胞提供“名单”，空转提供“门牌号”，两者合起来才更接近细胞身份

MAPPING

单细胞参考如何解释混合表达?

把一个 spot 看成不同细胞状态的混合，而不是一个“纯细胞”

空间 spot



混合信号

参考图谱提供候选组成

细胞类型 A

细胞类型 B

用表达相似度估计每种状态的贡献

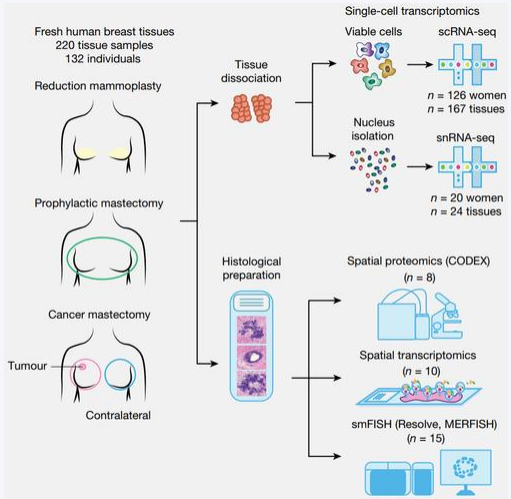
结果是推断，不是直接观测

去卷积解决的是“谁可能贡献了这个 spot”，不是“看到了一个完整细胞”

THE COUNTERINTUITIVE PART

为什么不能实现真正的一一对应?

两个数据集都带有位置，却不一定来自同一份组织、同一批细胞



同一组织可进入不同测量分支，身份与位置需要跨数据集对齐

三种不确定性

- 不是同一张切片
- 一个 spot 可能混合多个细胞
- 参考图谱未必覆盖所有状态

映射结果必须带着不确定性解释

空间定位提高了解释力，但不会把推断变成直接观测

QUALITY CONTROL

映射结果可信不可信?

至少要同时检查参考、覆盖、混合与空间回验

参考匹配度

是否来自相近组织

类型覆盖度

参考图谱缺谁

spot 混合度

纯度还是混合

空间回验

标记基因能否对上

把预测的细胞身份画回组织，再用已知标记检查

映射不是最后一步；回到空间中验证，才知道结果是否值得解释

QUESTION 01

异常发生在哪里?

同一个细胞状态，为什么只在组织的某些位置出现?

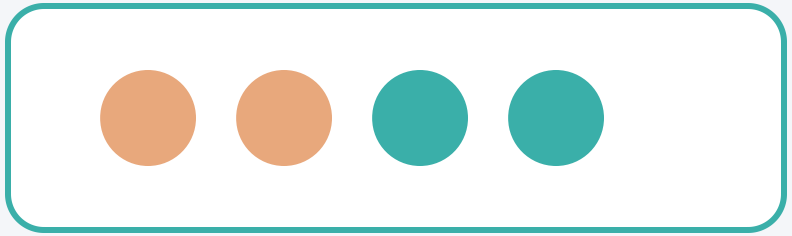
只看单细胞时



知道“有哪些状态”

却不知道它们出现在哪一层

空间分析多问一步



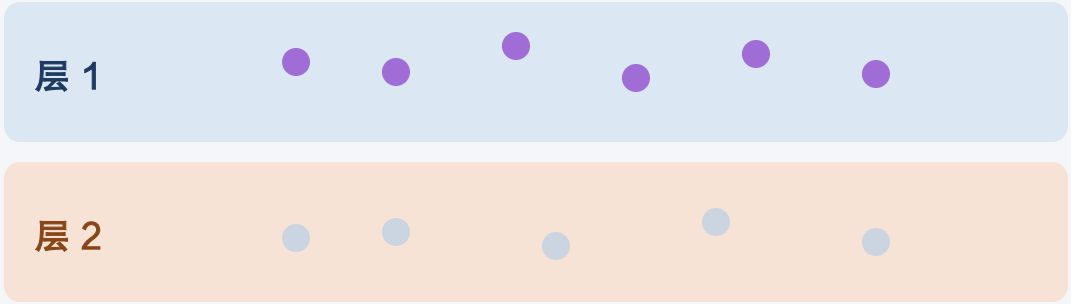
把异常状态放回组织地图

第一个问题不是“哪个基因变了”，而是“变化集中在哪里”

QUESTION 01 · EVIDENCE

空间可变特征，把异常放回组织

从“表达量不同”推进到“表达差异具有空间结构”



高值点（紫）集中在一层：这个特征具有空间结构
若它两层都一样多，就只是表达高低，不是空间结构

分析动作

1. 找到空间上不均匀的特征
2. 把信号画回切片
3. 对照组织结构与病理区域

空间结构是结果，不是装饰

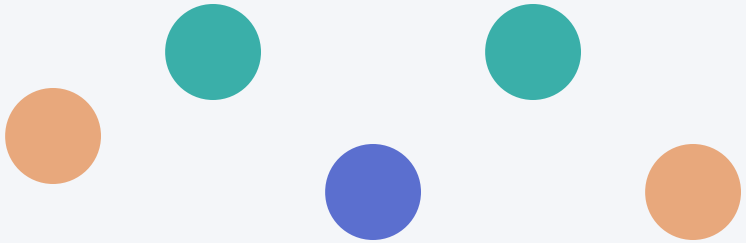
只有把信号放回切片，才能判断它是否属于某个组织结构

QUESTION 02

谁和谁真的在一起?

“组织里都有这些细胞”不等于“这些细胞彼此接触”

只看细胞名单



知道“有谁”，不知道“谁挨着谁”

空间分析新增一个关系



邻域，把“关系”变成数据

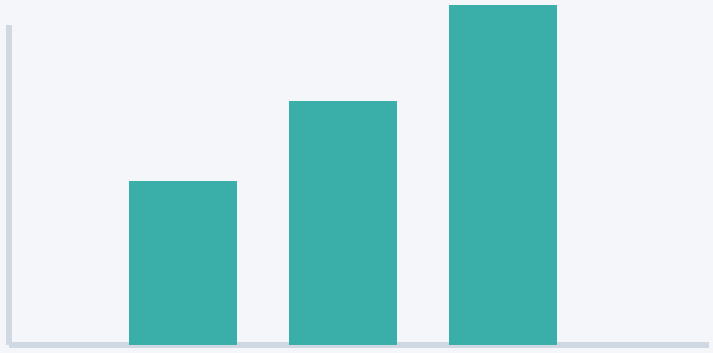
第二个问题：空间关系是否支持一个具体的生物学解释?

ABUNDANCE ≠ POSITION

丰度升高，不等于位置接近

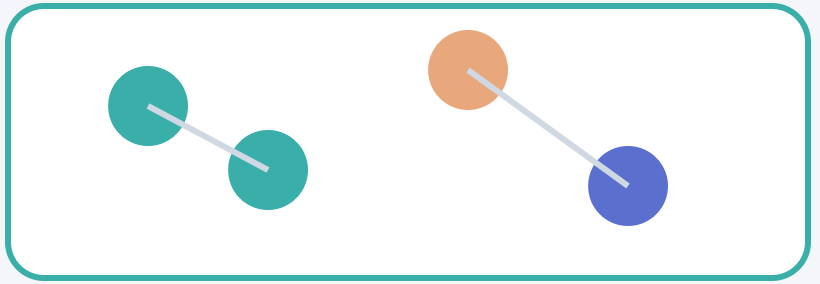
这是空间分析最容易被混淆的两个问题

丰度：有多少



整体比例或数量差异

位置：在哪里



邻域、边界与共聚集

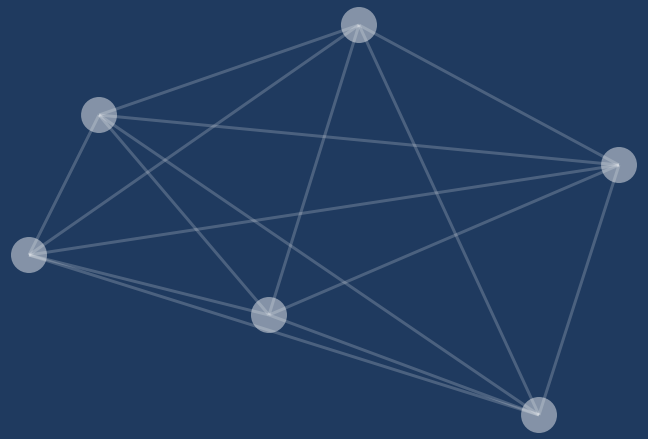
“多”回答数量，“近”回答关系；两者不能互相替代

PART 07

一件称手的工具

07

定性注释之后，谁来定量刻画功能活性?



- 研究背景：现有方法的三个缺口
- 方法设计：随机游走 + 空间自相关
- 研究范畴：全局、局部、双变量
- 评估验证：模拟数据有真值，才知道准不准

BACKGROUND

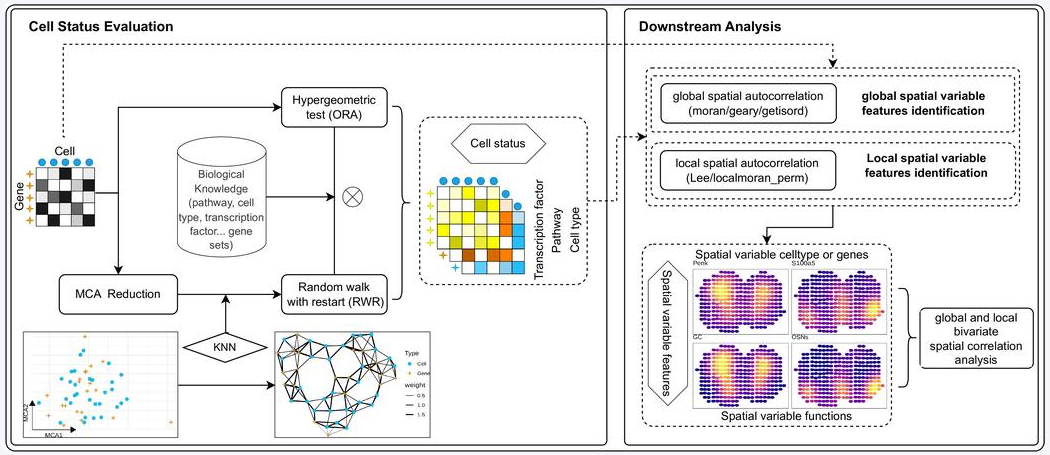
SVP 要回答的，是两个具体问题

准确描述细胞状态，并研究它们的空间分布规律

问题一：细胞状态是什么?

问题二：状态如何分布?

从功能活性出发，再进入全局、局部
与双变量空间结构。



SVP 框架：状态评估 → 空间特征识别
github.com/YuLab-SMU/SVP

SVP 把“细胞状态”和“空间结构”放进同一条分析链

QUESTION 1

问题一：如何定量刻画功能活性

从「这是什么细胞」到「这个细胞有多活跃」

目标

结合基因表达谱与生物医学知识，准确预测单个细胞或 spot 水平的功能活性状态

功能活性的类型

细胞类型活性、GO 功能活性、KEGG 通路功能活性、转录因子活性

产出

单细胞水平的细胞功能活性图谱

为什么需要

定性注释无法比较「哪里的功能更强」

现有工具

GSVA、SSGSEA、AUCell、CelliD、GSDensity 等

共同问题

在单细胞与空转的高稀疏数据中表现不佳，或无法做空间分析

把「有/没有」变成「有多少」，才能做空间上的比较

QUESTION 2

问题二：如何探索空间分布与共分布

四个层层递进的问题

第一层

特征是否高可变？即判断它在空间中是聚集、分散还是随机

第二层

特征在哪些区域聚集？即定位局部高聚集区域

第三层

哪些特征之间有共聚集现象？即双变量空间关联

第四层

这些共聚集特征在哪些区域共聚集？即局部双变量定位

现有工具

Trendsceek、SpatialDE、SPARK、SPARK-X、Squidpy、nnSVG、scGCO 等

现有工具的问题

内存需求高、运算效率低，且只能判断单一特征是否空间可变

能判断「是否可变」只是第一步，定位「在哪里聚集」才是关键

METHOD DESIGN

方法一与方法二，各自回答什么？

先看细胞功能活性，再看空间分布

方法一 · 功能活性

随机游走 + 超几何检验

从单细胞或 spot 的表达出发，
预测细胞功能活性。

目标：准确的功能活性图谱 + 大规模稀疏数据

方法二 · 空间模式

空间自相关

比较相邻位置的表达相似性，
鉴定空间可变特征及其共分布。

目标：解释空间分布规律与特征共分布

共同要求：低内存、高效率，适配越来越高的测序分辨率

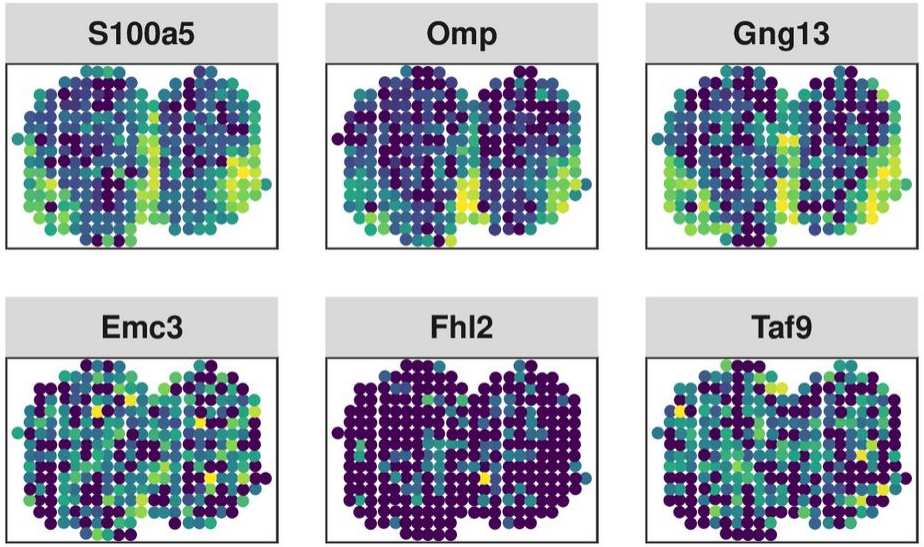
把成熟的统计工具迁移到新的空间数据场景

GLOBAL

全局指标：整张切片聚不聚

判断特征是聚集、分散，还是随机分布

- Moran's I：衡量空间自相关程度，正值表示聚集
- Geary's C：另一种空间自相关度量，与 Moran's I 互补
- Getis-Ord G：侧重高值或低值的聚集
- 在模拟数据上，用校正后的 p 值筛选可以降低假阳性
- 效果与经评估表现较好的工具（SPARK-X、nnSVG）结果相似



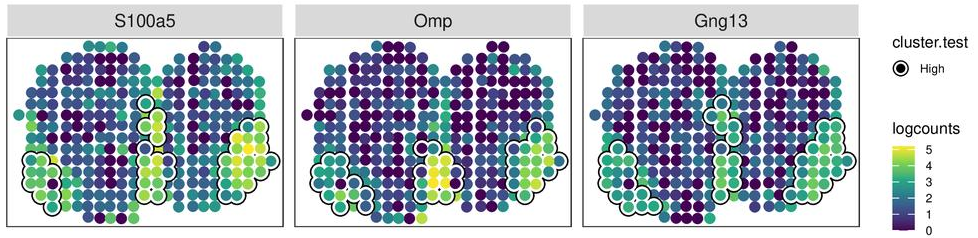
全局空间自相关指数

LOCAL

局部指标：聚集发生在哪一块

回答「在哪些区域聚集」

- Local G 与 Local Moran's I 是常用的局部指标
- 每个位置都会得到一个局部统计量
- 显著为正的位置，就是该特征的高聚集区域
- 显著为负的位置，则是低值聚集区
- 结果可以直接画在组织切片上，直观呈现



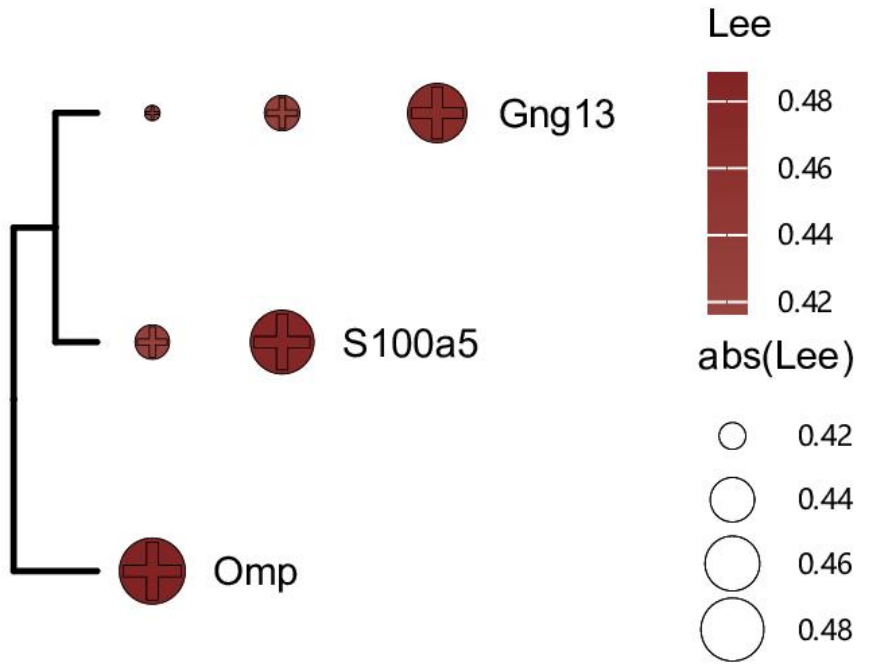
局部聚集区域的定位

BIVARIATE

两个特征，全局上是否一起聚集

Lee's L 结合空间邻接与两个特征的协同变化

- 目标：判断两个特征是否在空间上共聚集
- 双变量空间统计量：Lee's L：保留空间邻接
- 关键改进：考虑了 cell 的空间位置信息
- 不等于 Pearson 的线性相关空间邻接进入统计量
- 结果更符合「空间共分布」这一概念的本意

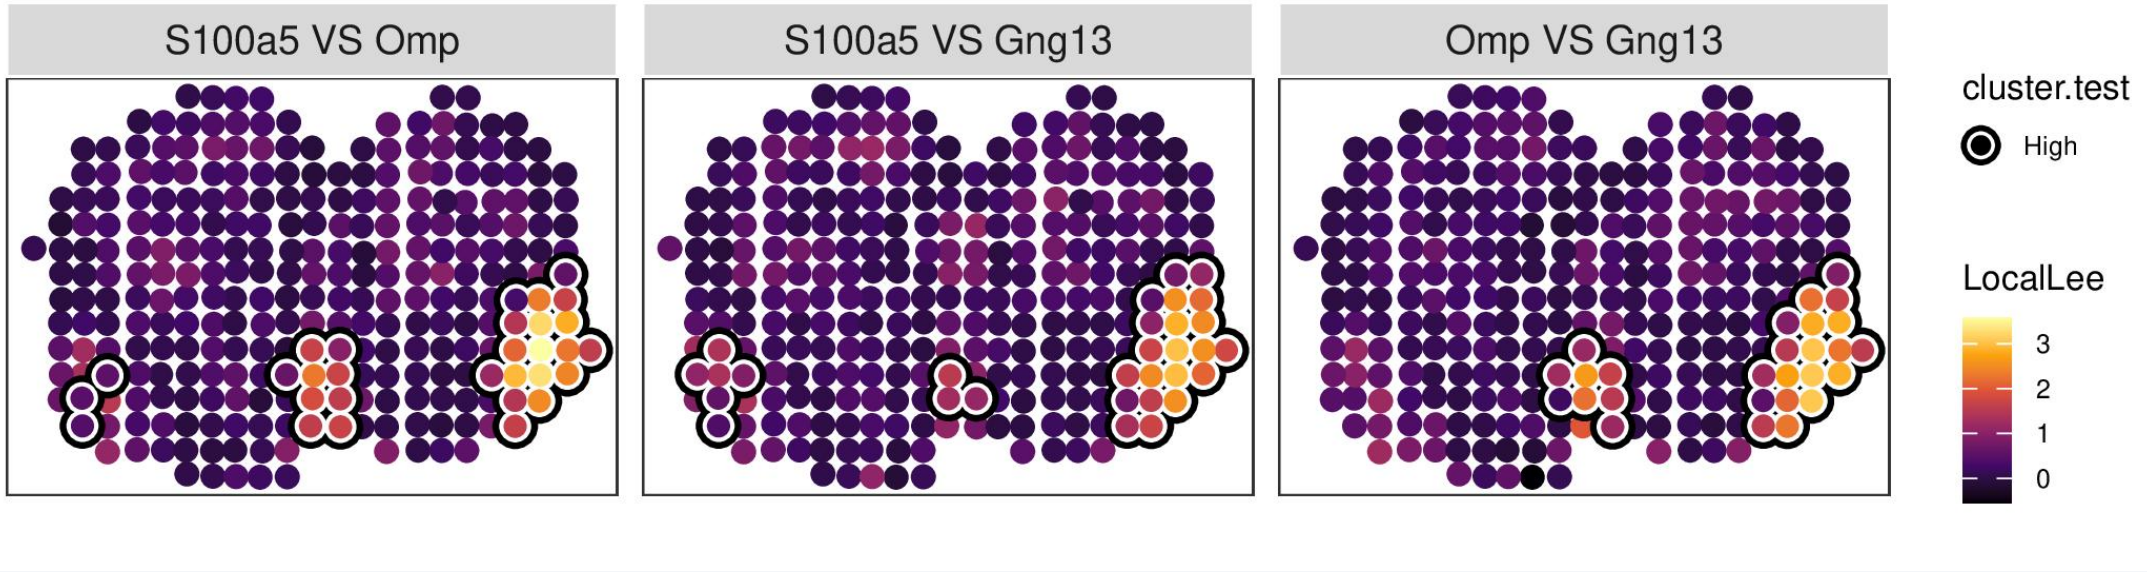


Lee's L：双变量空间关联的示例

LOCAL BIVARIATE

共聚集：哪一块里两个特征在一起

回答「在哪些区域共聚集」



S100a5 / Omp / Gng13 三对基因的局部共聚集（LocalLee），黑圈标出显著 spot

BENCHMARK

用模拟数据做系统评估

有真值，才能知道方法准不准

- 使用小鼠初级视觉皮层的 STARMap 数据作为模板
- 原始数据：1020 个基因、973 个细胞
- 模拟数据：108 个 spot、996 个基因
- 评估维度一：预测与真实细胞类型丰度的一致性
- 评估维度二：预测与真实空间分布（Moran's I）的一致性
- 评估维度三：计算资源与时间消耗

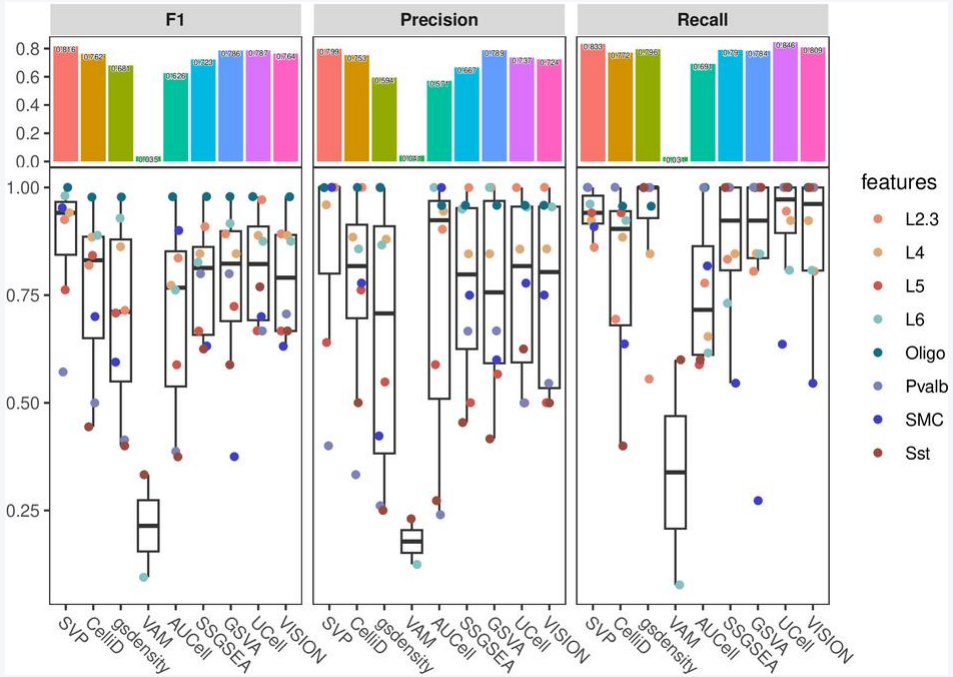


模拟数据的构建

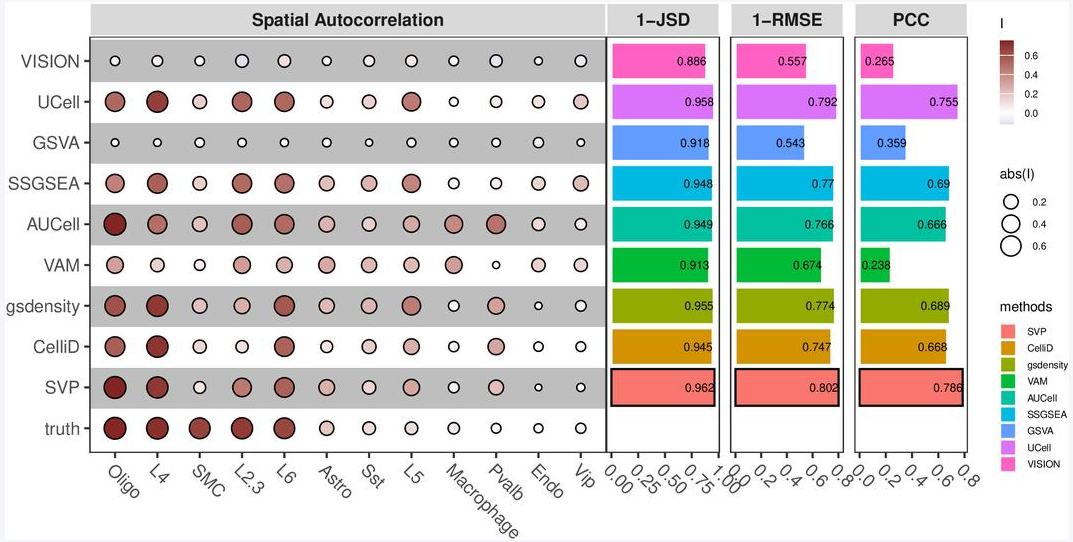
CONSISTENCY

预测质量与空间一致性都要看

先看细胞类型级别表现，再看空间分布是否保真



F1、Precision、Recall：细胞类型级别表现

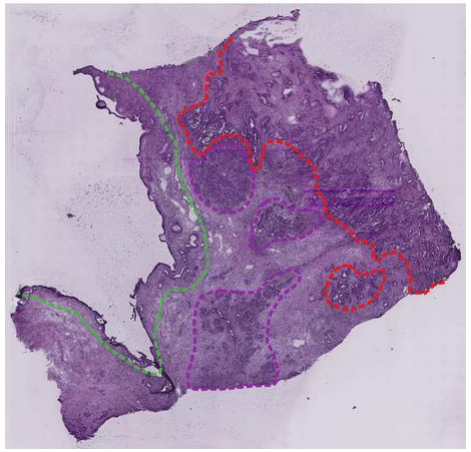


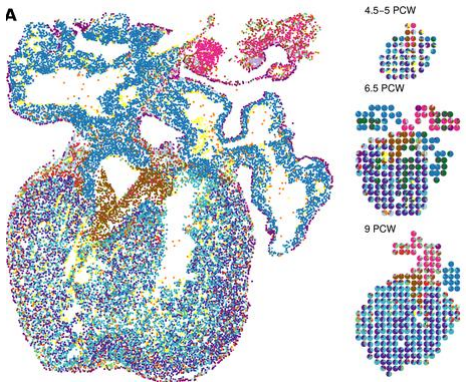
空间自相关与 1−JSD、1−RMSE、PCC 对比

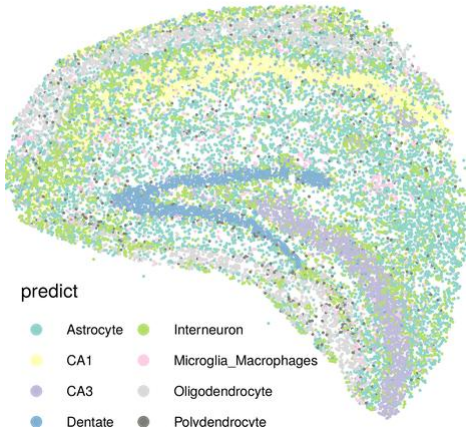
GENERALITY

同一个框架，三类组织都跑通

肿瘤、发育、神经退行——结论不依赖某一个数据集







肿瘤 · 胰腺导管癌

缺氧与 ECM 重塑生态位；
免疫细胞被排斥在肿瘤之外

发育 · 人心脏

随发育阶段推进，空间聚集
逐级增强

神经退行 · AD 模型

斑块邻近的小胶质与星形胶质
呈现清除与反应性程序

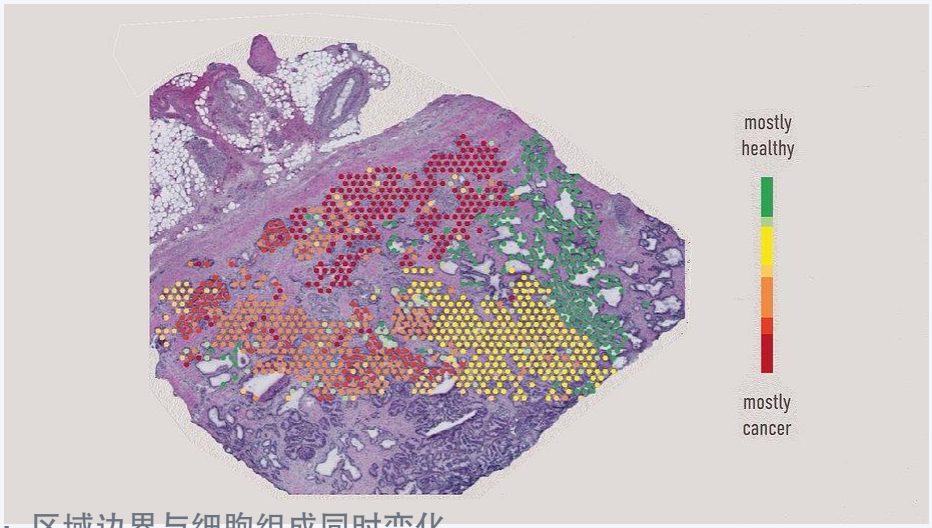
图：PDAC 组织学（Fig. 4A）、人心脏发育（Fig. 5A）、AD 模型海马（Fig. 6A）

方法的适用性来自框架，而不是来自某一个数据集

TUMOR MICROENVIRONMENT

肿瘤里有免疫细胞，为什么仍会免疫逃逸?

关键不只是“有多少”，还要看它们是否进入同一个空间邻域



肿瘤微环境：区域边界与细胞组成同时变化

要分开看两件事

丰度：有多少

位置：在哪里、和谁相邻

空间分析把“免疫逃逸”具体化

丰度升高，不等于进入了肿瘤细胞的邻域

QUESTION 03

相邻能不能叫“通讯”？

空间共聚集是线索，不是已经完成的机制证明



真正的证据还要包括：表达方向、密度校正、通路/靶基因和实验验证。

空间分析的产出是可检验的假说，不是自动成立的结论

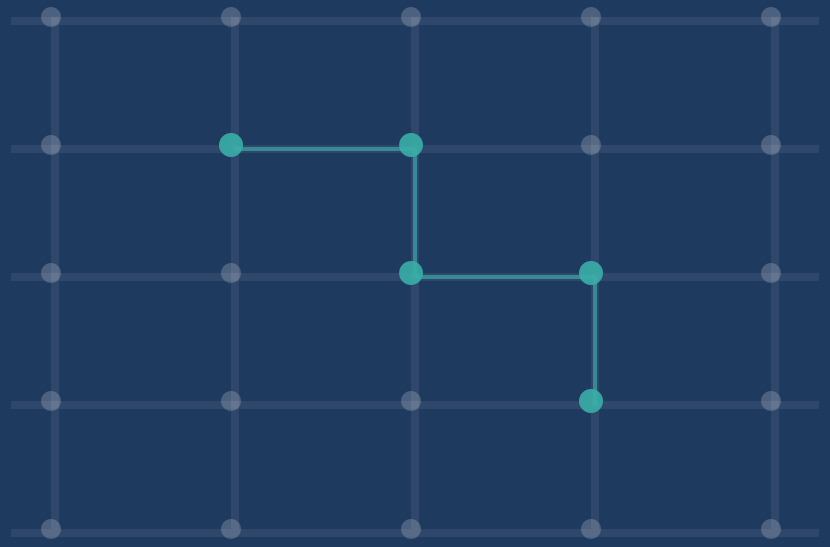
PART 08

名单变地图

08

人胰腺导管癌肿瘤微环境——谁和谁做邻居，用这份数据回答

- 区域分布：第一主成分分开四类区域
- 丰度差异：肿瘤侧多谁，非肿瘤侧多谁
- 共聚集：谁和肿瘤细胞挨在一起
- 机制落点：EMT 与缺氧指向免疫逃逸

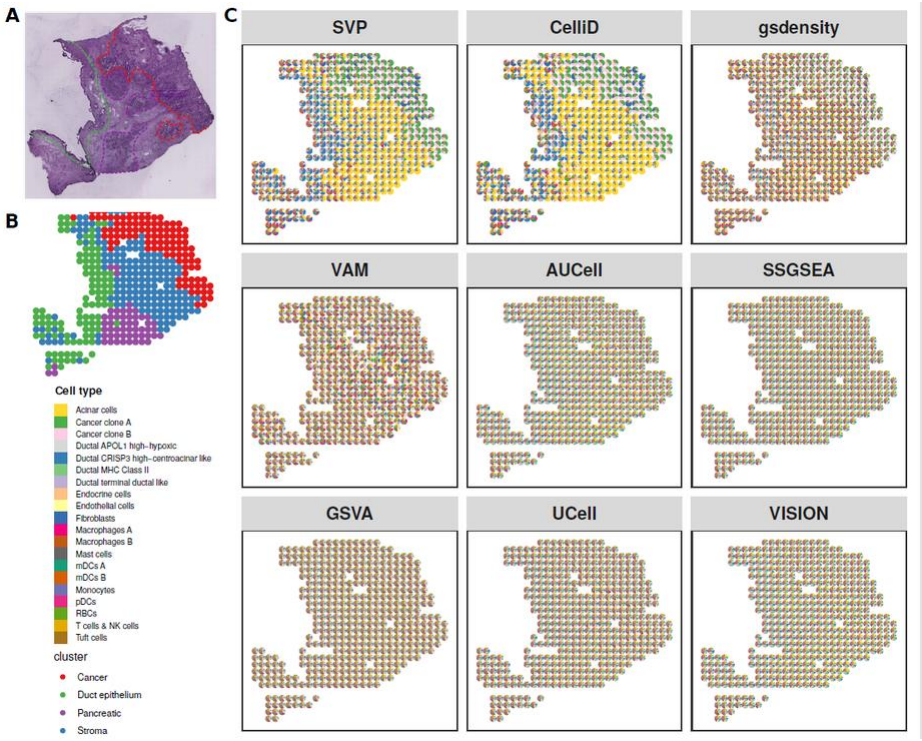


CASE STUDY

真实案例：不同方法的细胞类型注释

从细胞类型注释结果进入真实的肿瘤微环境

- 数据：人胰腺导管癌空间转录组与组织图像
- 图中比较：不同打分方法对细胞类型注释结果
- 观察：SVP 的空间分区较清晰，整体表现较好
  可作为后续区域比较的基础
- 下一步：比较区域、丰度与空间共聚集
- 真实数据的验证比模拟数据更有说服力



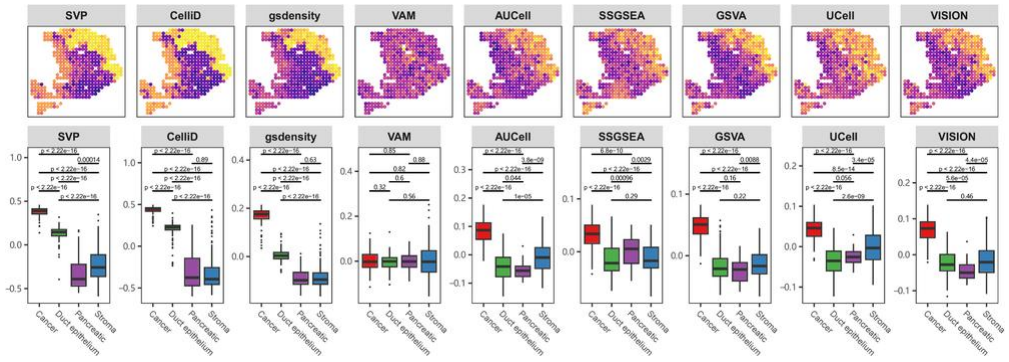
不同方法的细胞类型注释结果（SVP 分区较清晰）

CASE STUDY

第一主成分就把四类区域分开

对预测出的细胞类型活性做主成分分析

- 对 SVP 预测的细胞类型活性做 PCA 分析
- 第一主成分可以将癌症、胰腺、导管以及基质区域很好区分开
- 其他工具则无法有效区分
- 例如 CelliD、GSDensity 无法区分胰腺与基质区域
- 说明 SVP 的活性预测保留了区域特异性的信息



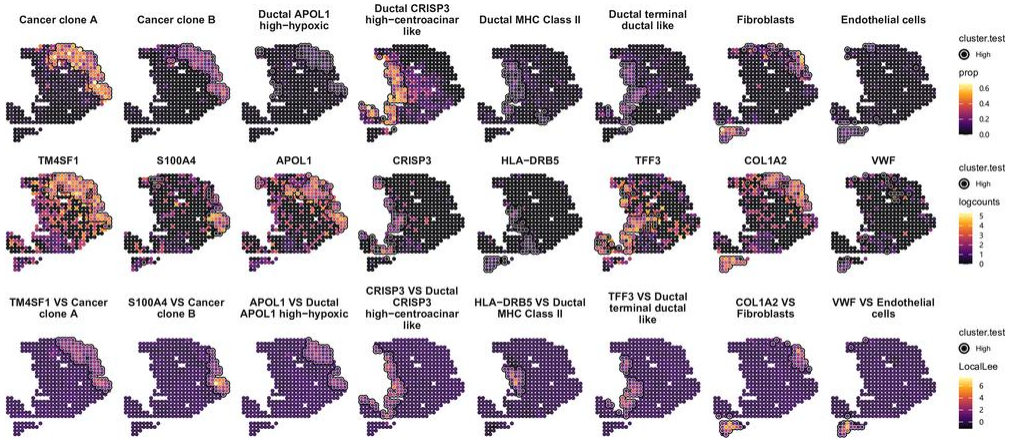
PCA 对区域的区分能力

CASE STUDY

活性预测与标记基因的空间一致性

预测结果能被已知标记基因验证

- SVP 预测的细胞类型活性
- 与对应细胞类型的标记基因
- 两者在空间上的分布高度一致
- 这是对预测结果最直接、最可信的验证
- 说明活性预测不是纯粹的数学产物，而具有生物学意义

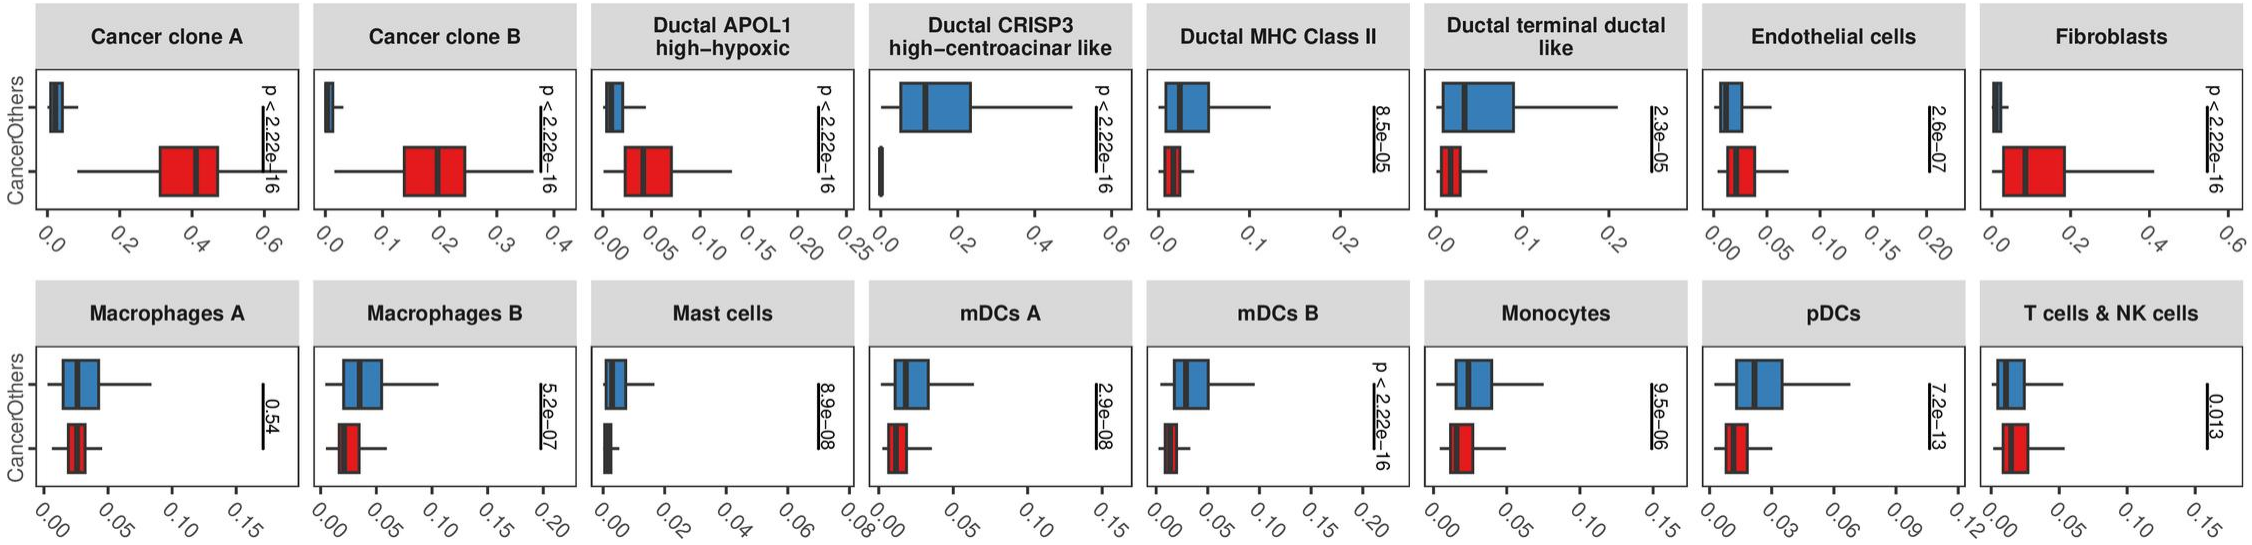


活性预测与标记基因的空间一致性

CASE STUDY

丰度差异：谁在肿瘤侧更多

哪些细胞在肿瘤区富集，哪些在正常区富集



- 肿瘤细胞、成纤维、内皮
  与缺氧导管都在肿瘤侧更高
- 巨噬细胞、pDC、肥大细胞
  与单核细胞在正常侧更高
- 免疫排斥的信号
  为后续免疫逃逸分析提供线索

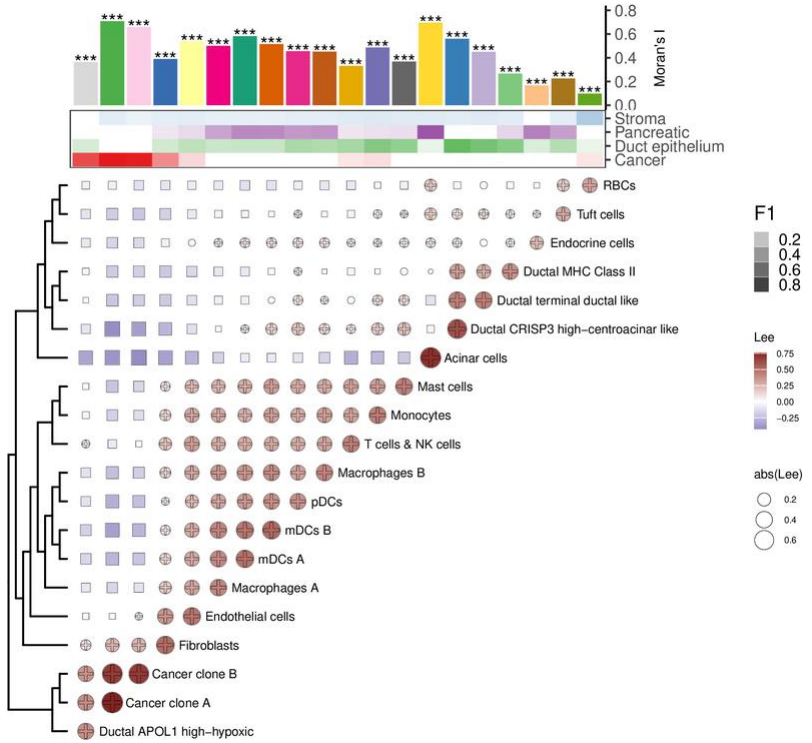
细胞类型丰度的区域差异（14 个细胞类型，肿瘤侧 vs 非肿瘤侧）

CASE STUDY

空间共聚集分析揭示免疫逃逸

谁和谁待在一起，谁被排斥在外

- 缺氧导管细胞、成纤维细胞、内皮细胞与肿瘤细胞在空间上显著共聚集
- 许多免疫细胞之间明显共聚集，但与肿瘤细胞没有明显共聚集
- 推论一：肿瘤细胞存在免疫逃逸
- 推论二：成纤维细胞、缺氧导管细胞、内皮细胞可能与肿瘤细胞存在细胞通讯
- 且这种通讯与免疫逃逸有关



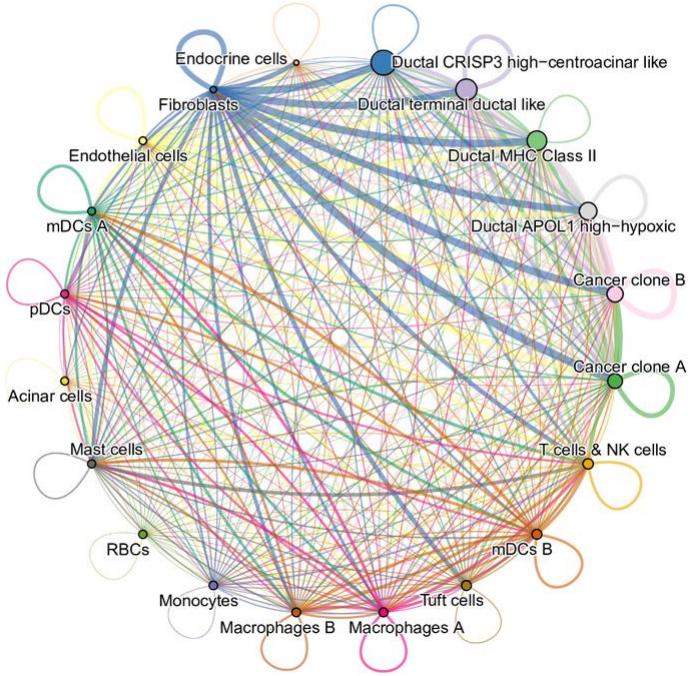
空间共聚集网络

CASE STUDY

共聚集提示的通讯，配受体对上了

成纤维、内皮与肿瘤细胞之间的配受体

- 成纤维细胞、内皮细胞与肿瘤细胞以及导管细胞存在明显的细胞通讯
- 通讯涉及的主要配受体与胶原、细胞间质相关
- 包括 COL1A1、COL1A2、FN1、THBS2、SDC1、SDC4、ITGA3 等基因
- 这些配受体基因在空间转录组上也有明显的空间共聚集
- 绝大多数聚集在肿瘤区域



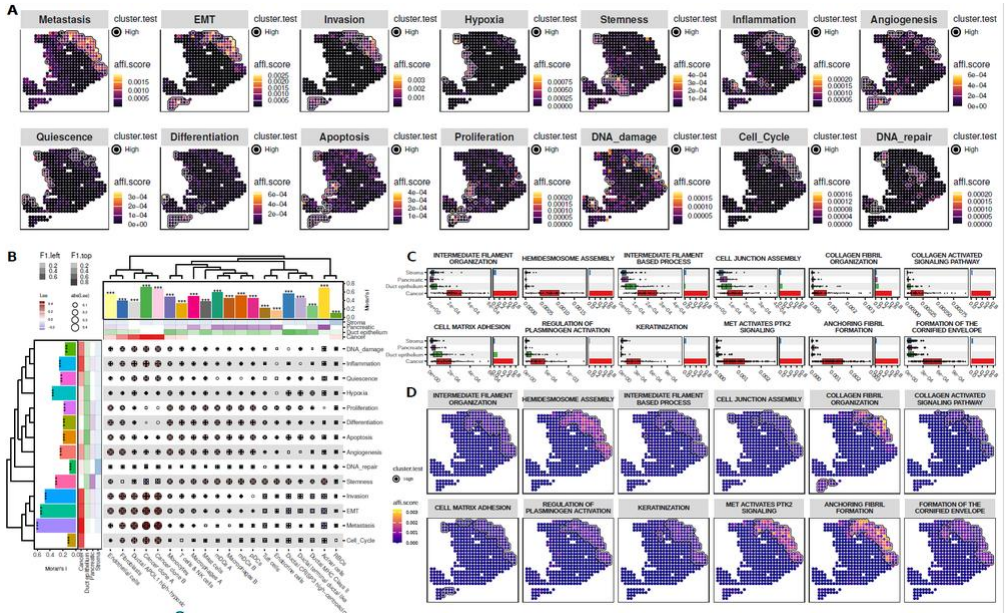
细胞通讯的配受体分析

CASE STUDY

从细胞层面走到分子机制

通路、转录因子与靶基因的三层证据

- Metastasis、EMT、Invasion、Hypoxia、Inflammation 等通路主要在肿瘤区域高聚集
- 其中转移、上皮间充质转化、侵袭最为明显
- 转录因子活性评估发现 AP1、BACH1、SUPT16H、TEF1、KMT2D 等显著高聚集在肿瘤区域
- 这些转录因子已被报道与肿瘤侵袭、转移、抗凋亡相关
- 其调控的靶基因（LAMC2、LAMB3、ITGA3、FN1、COL1A1 等）很多参与细胞通讯

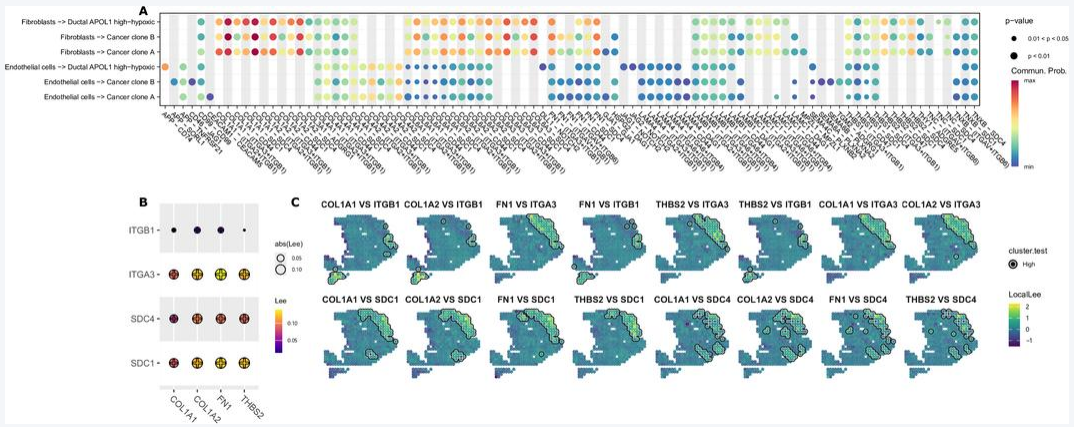


功能通路与转录因子活性

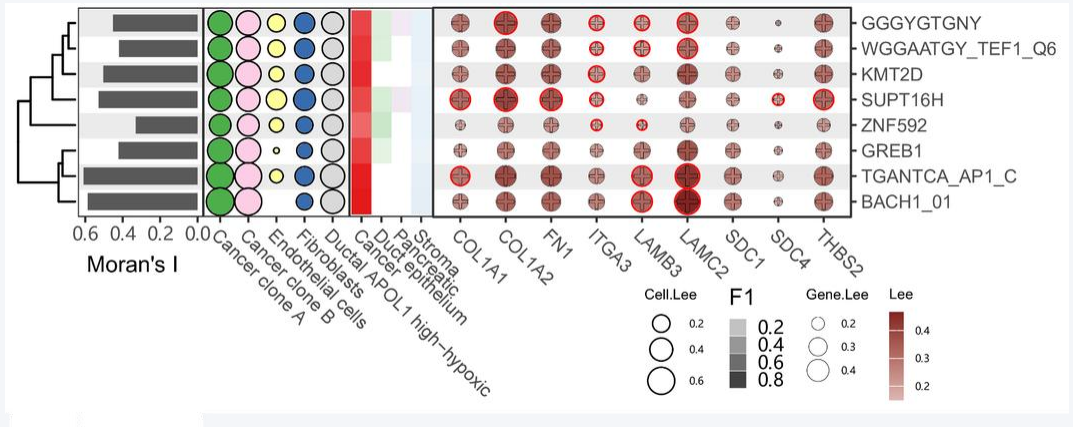
CASE STUDY

从空间模式到机制假说

所有线索汇聚成一个可检验的模型



配受体空间共聚集



转录因子与靶基因网络

回到开场那张满是零的表：缺失的信息靠更细的测量与更谨慎的统计补回，而不是被平均值抹去